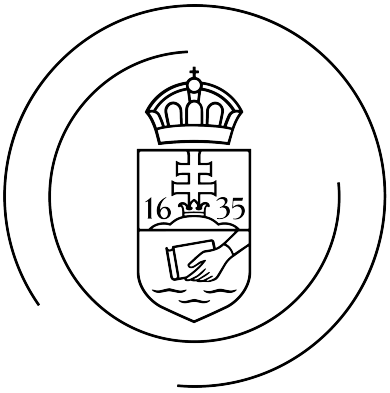
Eötvös Loránd Tudományegyetem Természettudományi Kar

Gépi tanuláson alapuló időjárás-előrejelző modell kaotikusságának vizsgálata légköri trajektóriákkal

Tudományos Diákköri Konferencia dolgozat



ELTE
EÖTVÖS LORÁND
TUDOMÁNYEGYETEM

Készítette: **Opposits Ágota**
Fizika BSc, meteorológus szakirány, III. évfolyam

Témavezető: **Leelőssy Ádám**
Egyetemi adjunktus

Témavezető: **Haszpra Tímea**
Tudományos főmunkatárs

Budapest, 2026

Tartalomjegyzék

1. Bevezetés **3**
1.1. Célkitűzés . . . 3
1.2. A mesterséges intelligencia és gépi tanulás . . . 3
1.3. Kaotikus neurális hálózatok . . . 9
1.4. Gépi tanulás alapú időjárás-előrejelző modellek . . . 10
1.5. MLWP-modellek kaotikus tulajdonságai . . . 13

2. Adat, módszer **15**
2.1. A trajektóriamodell . . . 16
2.2. Kaotikus viselkedés számszerűsítése . . . 17

3. Eredmények **17**
3.1. . . . 17
3.2. Szimulációs idők összehasonlítása . . . 17

4. Köszönetnyilvánítás **17**

Absztrakt

A mesterséges intelligencián alapuló időjárás-előrejelző modellek (Machine Learning Weather Prediction, MLWP) 2020-as évek elején történő elterjedése óta sok kutatás irányult a hagyományos előrejelző technológiáktól alapjaiban eltérő módszer adta lehetőségek vizsgálatára. A modern MLWP-modellek mély neurális hálózat alapúak, és egy költségfüggvény minimalizálására vannak betanítva. Az adatalapú megközelítés következtében a modellek nem ismerik expliciten a légkör kormányzó egyenleteit, amely fizikai inkonzisztenciákhoz vezethet. A szakirodalom jelenleg nem tekinti az MLWP-modelleket a légkör megfelelő szimulátorainak.

Kutatásomban trajektóriamodellezésen keresztül megvizsgálom, hogy a European Centre for Medium-Range Weather Forecasts (ECMWF) jelenleg élvonalbeli hagyományos, kaotikus jegyeket bizonyítottan mutató modelljével (IFS) szemben az MLWP-modellje (AIFS) mutat-e kaotikus viselkedést.

2026. június 1-jén UTC 0 órakor futtatott szélelőrejelzéseket használtam. Az előrejelzések tér- és időbeli felbontásának finomítása lineáris interpolációval történt. Egymáshoz közel indított részecskék trajektóriáira felírt, csak a szél sodrását figyelembe vevő differenciálegyenlet-rendszert adott izobárszinten a modellek szélsebesség-előrejelzéseit felhasználva numerikusan integráltam. A részecskéket összekötő fonal hosszának exponenciális időbeli változásából topologikus entrópia számolható.

Az IFS és AIFS esetében is sikerült exponenciális időbeli változást kimutatni, és pozitív topologikus entrópiát meghatározni, ami kaotikus viselkedésre utal. Durva térbeli felbontáson topologikus entrópia nem volt meghatározható. 150 óránál hosszabb előrejelzési időtávon az exponenciális kapcsolat az IFS-nél és AIFS-nél is kimutathatatlanná vált, ami a szomszédos részecskék egymástól való túlzott eltávolodásával, ezáltal pedig a topologikus entrópia alulbecslésével magyarázható. A vizsgált szinteken (500, 700, 850 hPa) az AIFS topologikus entrópiája jellemzően alacsonyabb, mint az IFS-é, melynek oka lehet az MLWP modellekre jellemző elmosódás jelensége. A vizuálisan ábrázolt, IFS szélelőrejelzésén alapuló trajektória-előrejelzések AIFS-énél komplexebb térbeli szerkezete is ezt támasztja alá. A földfelszín zavaró hatása megfigyelhető, magasabb nyomású izobárszinteken a topologikus entrópia magasabb.

Az alkalmazott lagrange-i megközelítés alapján tehát az AIFS is mutat kaotikus tulajdonságokat, ami azt jelenti, hogy a modell nem veszíti el teljesen a tanulás során a légkör ezen tulajdonságának reprezentálását, de az elmosódás hatása megfigyelhető.

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszert, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapú időjárás-előrejelző modellek (*Machine Learning Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [26]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; ECMWF-AIFS, 2024; illetve néhány ensemble modell: Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*Mean Squared Error, MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre. A modellfejlesztők a valósághű predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt [23].

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [6]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanná teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [30]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. A mesterséges intelligencia és gépi tanulás

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project*

on Artificial Intelligence). Felvetett elvük azon alapult, hogy „a tanulás minden aspektusa, vagy az intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet" [24, 8]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik; ezt nevezzük gépi tanulásnak [2].

Az első gépi tanulás alapú technológia az 1990-es években lett népszerű, amikor megjelentek az elektronikus levelezőrendszerekben a spamfilterek: a szűrő felhasználói bejelentésekből származó adatokon lett betanítva, megtanulva, hogy milyen jellemzői vannak egy spam e-mailnek. Az ezt követő évtizedekben egyre több gépi tanulás alapú technológia jelent meg, gondolhatunk itt a mindennapokban gyakran használt beszédfelismerő eszközökre, vagy a közösségi média tartalomajánló algoritmusaira [13]. A gépi tanulást 1959-ben Arthur Samuel amerikai informatikus így definiálta [20]:

> *A gépi tanulás képessé teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket.*

Egzaktabb definíciót nyújt Tom Mitchell szintén amerikai informatikus megfogalmazása [22]:

> *Egy számítógépes program valamilyen T feladat elvégzése érdekében – melynek sikerességét valamely P teljesítményt értékelő mérőszám jellemzi – E tapasztalatból tanul, ha a T elvégzése során nyújtott teljesítménye P mérőszámmal mérve az E tapasztalat megszerzésével javul.*

A gépi tanulás olyan problémák megoldásában lehet rendkívül hasznos, amik túl komplexek, vagy nem ismert algoritmikus megoldásuk. Ha megnézzük, hogy a gép milyen mintázatokat ismert fel vagy kapcsolatokat tanult meg, akkor az ember is új, addig még fel nem fedezett korrelációkat vehet észre, ami által a megértésünk javulhat, ezt nevezzük adatbányászatnak (*data mining*). A példák, tapasztalatok, amik segítségével a gép tanul, a tanító adathalmaz (*training set*) részét képezik (*sample*) [13].

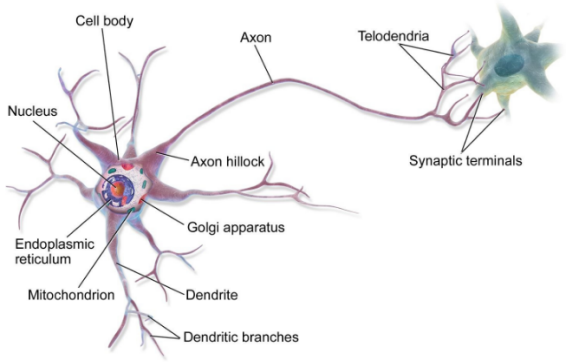
A gépi tanulásos rendszereket csoportosíthatjuk aszerint, hogy humán felügyelet alatt van-e tanítva (felügyelt – *supervised*, felügyelet nélküli – *unsupervised*, félig felügyelt – *semisupervised*, megerősítéses – *reinforcement* tanulás); menet közben tud-e fokozatosan tanulni (*online* és *batch* tanulás); illetve hogy az új adatokat a már ismertekhez hasonlítja (példa alapú – *instance-based* tanulás) vagy a tanító adathalmazban mintázatokat ismer fel, és ez alapján előrejelzést tud adni (modell alapú – *model-based* tanulás). A legfontosabb fogalmak a fentiek közül a felügyelt, felügyelet nélküli, illetve megerősítéses tanulás [13].

A felügyelt tanulás során a tanító adathalmaz tartalmazza a kívánt kimenetet / helyes megoldást (ezt nevezzük címkének – *label*). Példa lehet erre, hogy szeretnénk betanítani egy modellt, hogy korábbi eladási adatokat ismerve jelezze előre, mennyit ér egy eladásra szánt autó. Az autónak a tulajdonságai (*feature*; mint a kora, megtett km, márka stb.) adottak. Az előrejelezni kívánt numerikus mennyiséget hívjuk *predictor*-nek vagy *target*-nek (jelen esetben ez az autó ára). Az előrejelzéshez használt algoritmus többféle lehet, legismertebb példái a lineáris regresszió és a neurális hálózat architektúrák. Felügyelet nélküli tanulás során a tanító adathalmaz nincsen felcímkézve, a modell maga tanulja meg a jellemzőket elkülöníteni. Legismertebb példa a klaszterezés (*clustering*), amikor a modell a vizsgált adatokat a megfigyelt tulajdonságaik alapján osztályozza. Megerősítéses tanulás esetén a tanuló rendszer (az ágens – *agent*) megfigyeli a környezetét és a kialakított irányelvének (*policy*) megfelelően tetteket hajt végre. A tetteiért jutalmat (*reward*) vagy büntetést (*penalty*) kap. Az ágens célja a jutalom maximalizálása, ami érdekében iteratívan frissíti az irányelvét [13].

A gépi tanulás alapú modellek problémái legtöbbször a tanító adatból származnak: gondot jelent a nem megfelelő mennyiségű, minőségű, nem elég reprezentatív, vagy irreleváns adat. Ha a modell túl komplex a feladathoz, felléphet a túlillesztés (*overfitting*), ami azt jelenti, hogy az illesztett függvény

helytelenül a zajt is figyelembe vette. Ha a modell túl egyszerű, azt alulillesztésnek (*underfitting*) nevezzük. Az elkészült gépi tanulás alapú modelleket ezen hibák kiszűrése érdekében validálják, melynek népszerű eszköze az igazságmátrix (*confusion matrix*) [13].

A gépi tanulás hagyományosan statisztikai módszerek segítségével történik a megfigyelt adatok alapján. A gépi tanulás múlt században megalkotott, és az utóbbi évtizedekben elterjedt technikája egészen más megközelítést kínál; ezek a mesterséges neurális hálózatok (*Artificial Neural Network, ANN*). Az ANN-ek segítségével az adatbázisban fennálló komplex kapcsolatok is felismerhetőek [31]. Az ANN-eket 1943-ban mutatta be Warren McCulloch amerikai neurofiziológus és Walter Pitts számítógépes idegtudós. Az ANN-t mesterséges neuronok alkotják, melyek működését a biológiai neuronok ihlették, melyet az 1.1. ábra mutat be.



1.1. ábra. A biológiai neuron szerkezete. Az ábra Géron *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (2017) [13] könyvéből származik.

A biológiai neuron (idegsejt) az agykéregben előforduló sejt, melynek főbb részei a sejttest (*cell body*), a dendritek (*dendrite*), illetve a nagyon hosszú nyúlványa, az axon. Az axon telodendronokra bomlik, melyek csúcsán kis szinapszisok találhatóak, melyek a dendritekbe tudnak kapcsolódni és a neuronok kis elektromos impulzusokkal történő kommunikációjáért felelősek. Ha a neuron adott idő alatt elég jelet kap, maga is aktiválódik és jeleket ad le. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt [8]. Az agyban a neuronok egymás utáni rétegekbe vannak rendeződve, így lesz képes az emberi agy komplex feladatok elvégzésére is [13].

Az ANN rétegebe rendeződött neuronokból áll. A rétegekben csomópontok vannak, az információ feldolgozásáért felelős mesterséges neuronok pedig kapcsolatokon keresztül kommunikálnak egymással [32]. A csomópontok a biológiai neuron sejttestének feleltethetőek meg, a kapcsolatok pedig hasonlóan működnek, mint az axonok és dendritek. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [8].

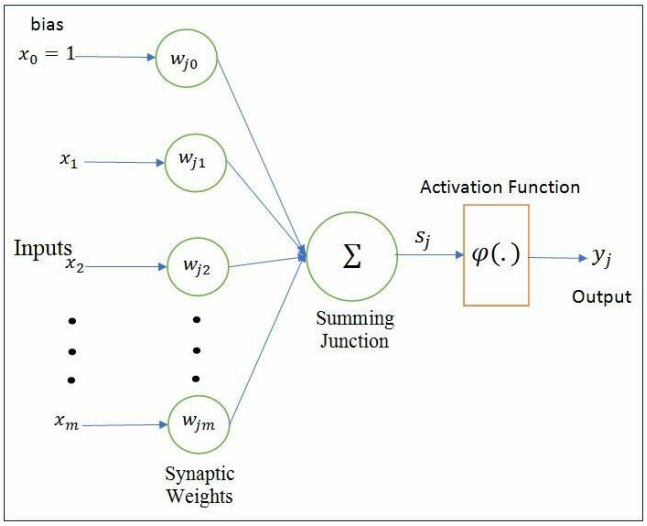
A McCulloch és Pitts által megalkotott ANN kijelentéslogikán alapult. A neuronok egy vagy több bináris (*on/off* típusú) bemenetet (*input*) fogadtak, és egyetlen kimenetet (*output*) adtak. A biológiai neuronok aktiválódását úgy imitálták, hogy a mesterséges neuron csak akkor adott kimenetet, ha a kapott bemenetek száma elért egy bizonyos értéket.

Az egyik legegyszerűbb neurális hálózat a Perceptron, melyet 1957-ben Frank Rosenblatt mutatott be. Úgynevezett küszöb logikai egységek (*Treshold Logic Unit, TLU*) a mesterséges neuronok, az input és output értékek pedig numerikusak; minden input – fontosságának megfelelően – súlyozva van. A súlyozott bemenetek mellett egy b konstans értéket felvevő elfogultság (*bias*) is hozzáadásra szokott kerülni. A TLU egy súlyozott összeget számol, majd egy nemlineáris aktivációs függvényt hattat az eredményre, és ezt adja outputnak. Az aktivációs függvényre azért van szükség, hogy a lineárisnál bonyolultabb kapcsolatokat is képes legyen megtanulni az ANN. Aktivációs függvény lehet pl. a Heaviside-féle egységfüggvény, ReLu (*REctified Linear Unit*, ami a negatív értékeket lenullázza), de

gyakran valamilyen szigmoid függvényt alkalmaznak a célra, mint a tangens hiperbolikusz vagy a logisztikus függvény. A mesterséges neuron működését az alábbi egyenlet foglalja össze:

$$s_j = \sum_{i=1}^{m} w_{ij} \cdot x_i + b_j; \quad \hat{y_j} = \varphi(s_j),$$

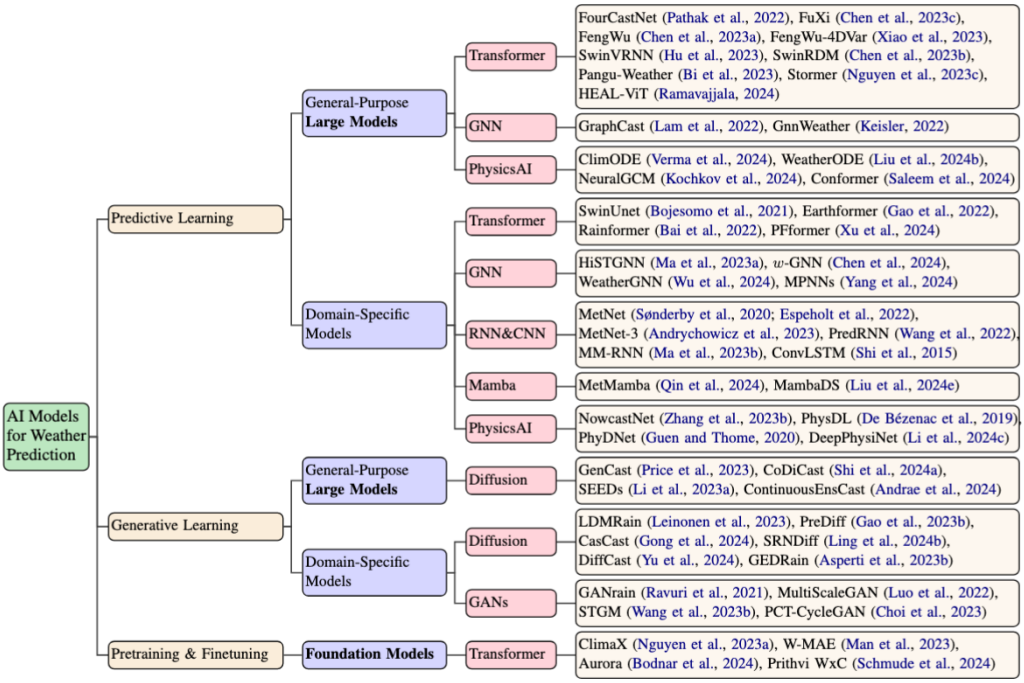
ahol x_i az input, b_j a bias, w_{ij} a súlymátrix, s_j a súlyozott összeg, φ az aktivációs függvény, $\hat{y_j}$ pedig az output. A fentebb leírt mesterséges neuron működését mutatja be a 1.2. ábra. [32, 13, 17].



1.2. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [32] cikkéből származik.

Egyszeres neuronréteg azonban csak egyszerűbb feladatok elvégzésére alkalmazható; ha bonyolultabb problémákat szeretnénk megoldani, több rétegre van szükség. A kettőnél több rétegből álló ANN-t mély neurális hálózatnak (*Deep Neural Network, DNN*) nevezzük. Ennek legegyszerűbb példája a többrétegű Perceptron (*Multilayer Perceptron, MLP*), ami több rétegnyi TLU-ból áll, melyeket rejtett rétegeknek (*hidden layers*) nevezünk. Minden réteg teljesen hozzá van kapcsolva a szomszédos réteghez (*Fully Connected, FL*) [13].

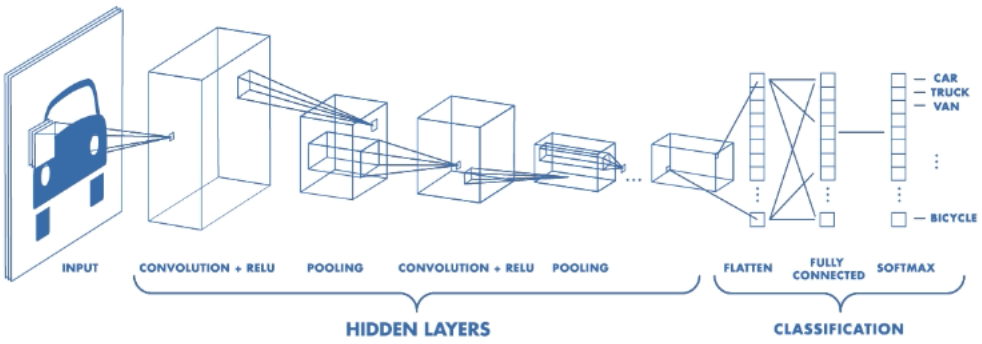
A bonyolultabb feladatok elvégzésére tehát mélytanulásos (*Deep Learning, DL*) technológiák alkalmasak. Mélytanulásos architektúra többek között a konvolúciós neurális hálózat (*Convolutional Neural Network, CNN*), rekurrens neurális hálózat (*Recurrent Neural Network, RNN*), a gráfalapú neurális hálózat (*Graph Neural Network, GNN*), a transzformer architektúra (*Transformer*), vagy a Vision Transformer [33]. Az időjárás-előrejelzésben használt MLWP-modellek áttekintését mutatja a 1.3. ábra.



1.3. ábra. Az MLWP-modellek áttekintése. Az ábra Shi et al. (2025) [33] cikkéből származik.

Ahogy az ábrán is látható, az MLWP-modelleknek alapvetően három fajtája van. Legelterjedtebbek az általános célú nagy modellek (*General-Purpose Large Models*), melyek többféle időjárási paraméter globális előrejelzésére alkalmasak. Az operatív időjárás-előrejelzésben kevésbé elterjedtebbek a domén specifikus modellek (*Domain-Specific Models*, melyekkel regionális előrejelzést lehet készíteni egyetlen változóra), illetve az alapmodellek (*Foundation Models*, melyekkel még további finomhangolás, specifikus feladathoz adaptálás lehetséges). Az is megfigyelhető, hogy az utóbbi években a CNN és RNN alapú időjárás-előrejelző modellek háttérbe szorultak a GNN és transzformer architektúrájú modellek mellett.

A CNN architektúrát LeCun et al. mutatta be 1995-ben [19]. Az architektúra sturkturált rácsadatok, mint pl. a képek feldolgozására alkalmas; klasszikusan a gépi látás területén (pl. képosztályozás) CNN modelleket használnak [33]. A CNN-nek négy rétege van (konvolúciós réteg – *convolutional layer*, gyűjtőréteg – *pooling layer*, teljesen összekötött réteg – *fully connected layer* és a nemlineáris réteg – *nonlinearity layer*), melyeket a 1.4. ábra szemléltet. A rétegek szerepét egy képosztályozási feladaton keresztül mutatom be.



1.4. ábra. A CNN szerkezete. Az ábra Purwono et al. (2022) [27] cikkéből származik.

A CNN az inputként kapott képet egy mátrixként látja, ahol a mátrix minden eleme az adott pixel

fényintenzitását reprezentálja. A konvolúciós réteg (*convolutional layer*) a képekből a jellemzőket (*feature*, pl. élek, textúrák, minták) nyeri ki. A gyűjtőréteg (*pooling layer*) konvolúciós rétegeket kapcsol össze; szerepe a paraméter- és ezáltal számítási teher csökkentése a konvolúciós réteg kimeneteinek alulmintavételezett reprezentáció készítésével. A teljesen összekapcsolt réteg (*fully connected layer*, más néven konvolúciós output réteg – *convolutional output layer*) bemenete az utolsó pooling réteg. Az adatot a következő rétegbe továbbítás előtt vektorrá lapítja. Az utolsó réteg a nemlineáris réteg vagy aktivációs függvény (*nonlinearity layer / activation function*); ez a réteg adja meg a neurális hálózat végső kimenetét, a válaszát az adott feladatra [27].

Az RNN-eket 2001-ben mutatta be Medsker & Jain [21], mint időfüggő vagy szekvenciális adatokkal kapcsolatos feladatok (pl. idősor-előrejelzés) végzésére alkalmas architektúrákat. A modell rekurrens módon tanul a kapott adatsorozatból egy belső rejtett állapot segítségével, ami tartalmazza a korábbi rejtett állapotokat és az aktuális bemenetet. A tanulás folyamatát az alábbi egyenletek írják le:

$$h_t = \sigma(\mathbf{W}_x x_t + \mathbf{W}_h h_{t-1} + b_h); \quad y_t = \sigma(\mathbf{W}_y h_t + b_y),$$

ahol a t-edik időpillanatban h_t a rejtett állapot, x_t az input, y_t az output; $\mathbf{W}_x, \mathbf{W}_h, \mathbf{W}_y$ súlymátrixok, b_h, b_y bias-ok, σ pedig az aktivációs függvény. A CNN-nél és RNN-nél sokkal fontosabb architektúrák azonban az időjárás-előrejelzésben a GNN-ek és a transzformer alapú neurális hálózatok [33].

A GNN-t 2008-ban mutatták be Scarselli et al. [29]. Az architektúra $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ $\mathcal{V}$ csúccsal és $\mathcal{E}$ éllel rendelkező gráf szerkezetű adatok feldolgozására alkalmas, ahol a csúcsok a vizsgált dolgokat, az élek pedig a köztük fennálló kapcsolatokat reprezentálják. Ha a GNN a tér- és időbeli függőségeket is jól modellezik, tér-idő GNN-ekről (*Spatio-temporal GNN, ST-GNN*) beszélünk, melyeket a $\mathcal{G}_t = (\mathcal{V}, \mathcal{E}, t)$ jelöléssel szoktak illetni. Itt a csúcsok és az élek térbeli kapcsolatokat írnak le; a vizsgált dolog i térbeli helyen és t időpillanatban felvett vektorát a v_t^i vektor reprezentálja. A térbeli függőségek figyelembevétele az egyes csomópontok szomszédaikkal való kommunikációján (*message passing*) keresztül valósul meg. Az időbeli kapcsolatokat szekvenciális modellekkel (mint az RNN) lehet figyelembe venni. A csomópontok h_t^i rejtett állapotai a v_{t+1}^i üzenetvektorokkal kerülnek frissítésre az alábbi módon:

$$v_{t+1}^i = \sum_{j \in N(i)} M_t(h_t^i, h_t^j, e_{ij}); \quad h_{t+1}^i = \sigma(h_t^i, v_{t+1}^i),$$

ahol $N(i)$ az i-edik csomópont szomszédjai, M_t az üzenetküldő függvény, e_{ij} pedig az i-edik és j-edik csomópont közti élet jellemzi [33].

Az utóbbi évek legnépszerűbb mesterséges intelligencia-alapú modelljeinek alapjai a transzformer architektúrák. 2017-ben jelent meg Vaswani et al. a transzformer neurális hálózatokat bemutató azóta már nagyon híressé vált cikke, az „Attention Is All You Need” [35]. Az architektúra a figyelem mechanizmus (*attention mechanism*) alapján működik; szekvenciális lépések közbeiktatása nélkül képes az adatban fennálló kapcsolatokat megragadni. A figyelem mechanizmus az alábbiak szerint írható le:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V},$$

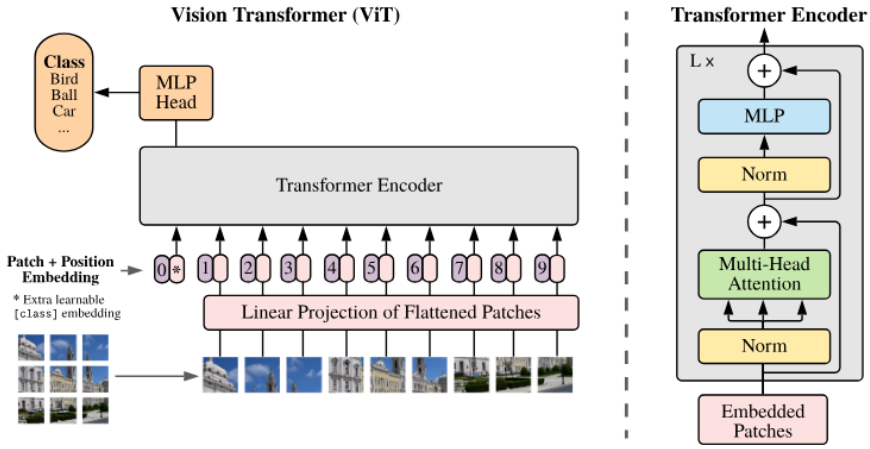
ahol d_k a $\mathbf{K}$ kulcsmátrix (*key matrix*) dimenziója, $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$ a lekérdezési mátrix (*query matrix*), $\mathbf{K} \in \mathbb{R}^{m \times d_k}$ a kulcsmátrix, $\mathbf{V} \in \mathbb{R}^{m \times d_v}$ az értékmátrix (*value matrix*). Ezeket a mátrixokat az $\mathbf{X} \in \mathbb{R}^{n \times d}$ bemeneti szekvenciális adatokat tartalmazó mátrix alapján az alábbiak szerint számolják ki:

$$\mathbf{Q} = \mathbf{X}\mathbf{W_q}, \quad \mathbf{K} = \mathbf{X}\mathbf{W_k}, \quad \mathbf{V} = \mathbf{X}\mathbf{W_v},$$

ahol $\mathbf{W_q} \in \mathbb{R}^{d \times d_k}$, $\mathbf{W_k} \in \mathbb{R}^{d \times d_k}$, $\mathbf{W_v} \in \mathbb{R}^{d \times d_v}$ rendre a **Q, K, V** mátrixokhoz tartozó tanulható súlymátrixok [33].

A Vision Transformer-t (*ViT*) Dosovitskiy et al. mutatta be 2021-ben [11]. Ez egy olyan transzformer, amely képek feldolgozására lett kifejlesztve. A ViT a bemenetként kapott képet rácsos szerkezetben részekre (*patch*) osztja; ezeket az adat-darabokat (úgynevezett *tokeneket*) alakítja aztán vektorrá

és dolgozza fel. Az így előkészített tokeneket továbbítják aztán egy transzformerbe, ahol a figyelem mechanizmus már alkalmazható. A Vision Transformer szerkezetét mutatja a 1.5. ábra.



1.5. ábra. A ViT szerkezete. Az ábra Dosovitskiy et al. (2021) [11] cikkéből származik.

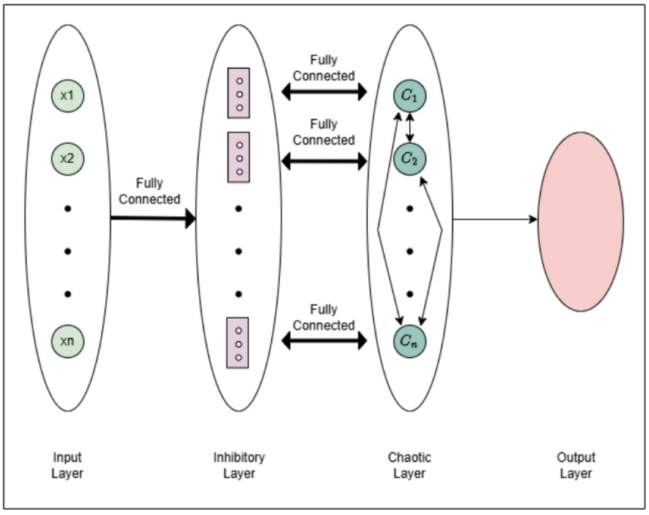
1.3. Kaotikus neurális hálózatok

A káosz görög eredetű szó, eredeti jelentése „tátongó űr”. Máshogy megfogalmazva a káosz egy komplex rendszer viselkedésében megnyilvánuló teljes zűrzavar vagy kiszámíthatatlanság. A káoszt a kezdeti feltételekre való rendkívüli érzékenységgel szokás azonosítani, ami a hosszútávú idősor-előrejelzést lehetetleníti el. Ezt először Henri Poincaré francia matematikus figyelte meg a 19. században, majd 1963-ban Edward Lorenz angol matematikus és meteorológus fogalmazta meg a káoszelméletet; tőle származik a „pillangóhatás” kifejezés is. Lorenz egy modellt készített, ami a légköri mozgásokat hivatott reprezentálni. A számításai során látszólag elhanyagolható kerekítéseket végzett, azonban észrevette, hogy ez az előrejelzésben rendkívül nagy eltéréseket okozott. Ez a kezdeti feltételekre való érzékenység koncepciója. Az 1989-ben Benoît Mandlebrot fedezte fel a fraktálok (önhasonló objektumok; a „káosz mintázatai”) jelentőségét a kaotikus attraktorok leírásában. [5, 3].

Ahhoz, hogy egy rendszer kaotikusnak nevezhessünk, az alábbi jellemzőknek kell teljesülnie:

- Nem jelenik meg periodikusság.
- Kezdeti feltételekre való érzékenység.
- Kaotikus mozgást nehéz vagy lehetetlen előrejelezni.
- Véletlenszerűnek látszó (de valójában determinisztikus) mozgás.
- Nemlineáris.

A kaotikus neurális hálózatokat (*Chaotic Neural Network, cNN*) – a káoszelmélet és neurális hálózatok ötvözetét – Aihara et al. mutatták be 1990-ben [1]. A cNN-ek a kaotikus rendszerek komplex mintázatait képesek reprezentálni és változatos megoldásokat tudnak felfedezni. A cNN neuronjai nemlineáris aktivációs függvények által kaotikus dinamikát mutatnak, amely egy ún. bifurkációs paraméter változtatásával szabályozható. Ez azért hasznos, mert így a neurális hálózat komplex – kaotikus – kapcsolatokat is felfedezhet az adatok közt. [3]. A kaotikus neuron szerkezetét a 1.6. ábra mutatja be.



1.6. ábra. A kaotikus neuron szerkezete Crook & Scheper (2001) [9] alapján. Az ábra Anusree & Pramod (2025) [3] cikkéből származik.

A bemutatott kaotikus neuron három rétegből áll. A bemeneti (*input*) réteg fogadja a bejövő dinamikus jeleket. A réteg teljesen össze van kötve (*fully connected*) egy gátló neuronokból álló klaszterek alkotta réteggel (*inhibitory layer*). Egy-egy ilyen klasztert alkotó neuronok mindegyik a következő, kaotikus (*chaotic*) réteg ugyanazon neuronjához kapcsolódik. A kaotikus réteget alkotó minden egység teljes összeköttetésben van a többi egységgel [3].

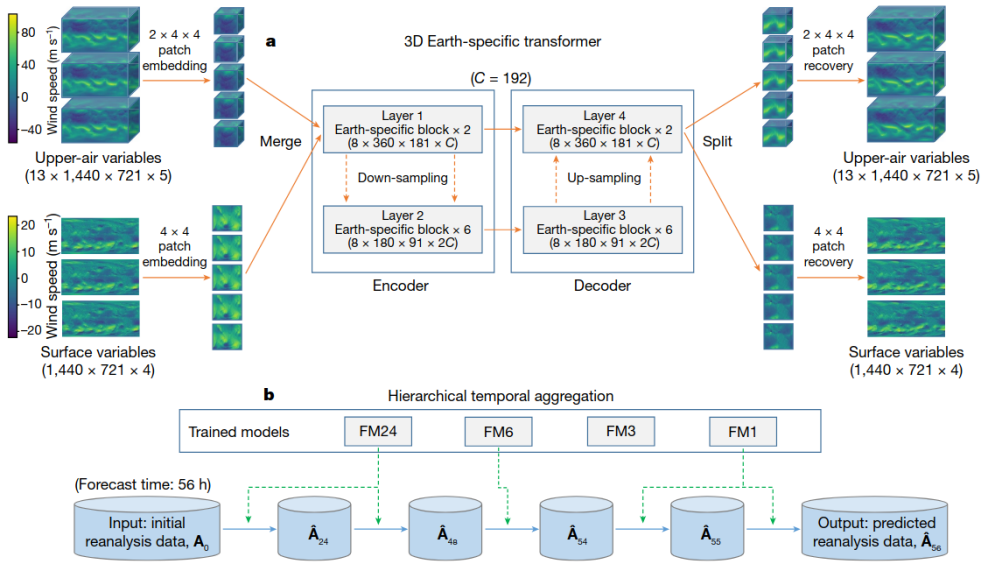
A cNN-ek tehát le tudják képezni a kaotikus jellemzőket. Jelenleg azonban főként arra használják a technológiát, hogy a tanítás során a modell ne ragadjon bele lokális minimumokba [3]. Az Echo State Network-öt (*ESN*) – egy olyan neurális hálózat, ami bizonyos körülmények között képes kaotikus tulajdonságokat produkálni – Ortiz et al. (2025) [25] már használták a meteorológia területén, felhőzet-előrejelzésre. Azonban a kaotikus neurális hálózatok gépi tanulás alapú időjárás-előrejelző modellekbe való integrálása még nem terjedt el széleskörűen, nem találkoztam ilyen jellegű tanulmányokkal a szakirodalmi kutatásom során.

1.4. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják (ld. pl. Hung et al., 2009, akik ANN-t használtak az eső előrejelzésére Bangkokban [16]), azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív, több időjárási változóra is kiterjedő előrejelzést lehessen készíteni segítségével [10].

Az első jelentősebb ANN architektúrán alapuló MLWP-modell az NVIDIA 2022-ben bemutatott, Fourier neurális hálózat alapú FourCastNet (*FOURier ForeCASTing Neural NETwork*) nevű modellje. Az architektúra alapötlete a fentebb már ismertetett ViT. Azonban a ViT erőforrásigénye a pixelszámokkal négyzetesen nő, így sokdimenziós bemeneti adatoknál már nem érdemes használni. Ezen probléma áthidalására fejlesztették ki Guibas et al. 2022-ben az Adaptív Fourier Neurális Operátorokat (*Adaptive Fourier Neural Operator, AFNO*). A módszer a függvények Fourier-terén hat, ami sok számítást leegyszerűsít (pl. a konvolúcióból szorzás lesz). Az AFNO lényegében a ViT módszert váltja fel [26, 12].

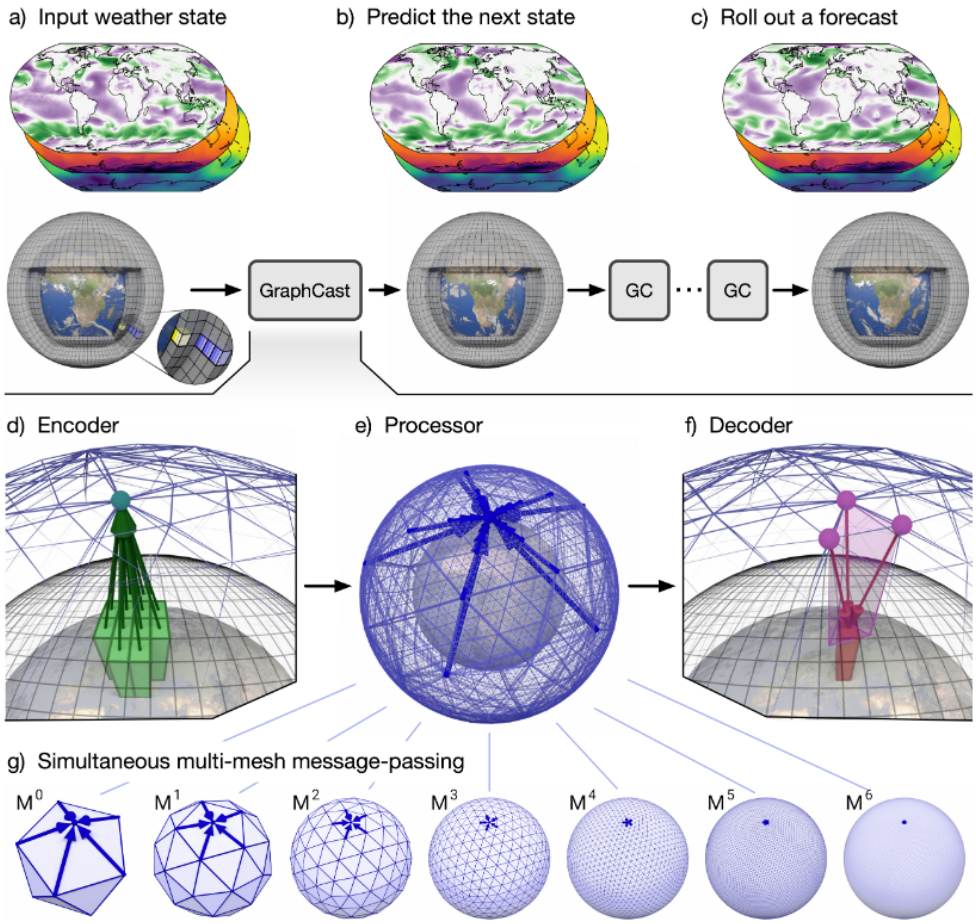
Szintén híres MLWP-modell a Huawei által 2023-ban bemutatott Pangu-Weather. A modell egy ún. 3D-s Föld-specifikus transzformer (*3D Earth-Specific Transformer, 3DEST*), melynek szerkezetét a 1.7. ábra mutatja be.



1.7. ábra. A 3DEST szerkezete. Az ábra Bi et al. (2023) [4] cikkéből származik.

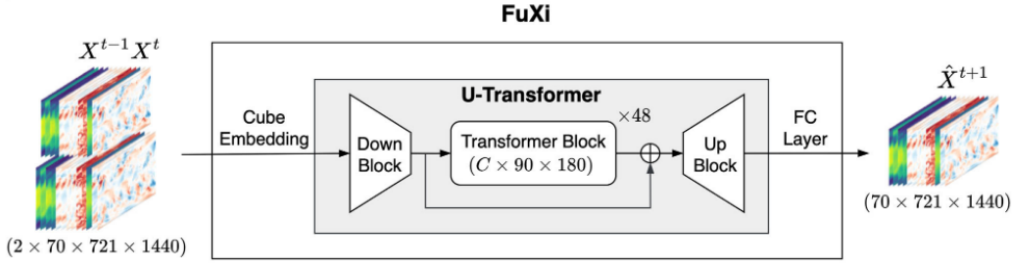
A 3DEST architektúra a bemenő adatokon ún. *patch embedding*et végez, ami során a térbeli felbontást lecsökkenti és egy 3D-s kockába sűríti. Ezt követően a hálózat a 3D-s adatokat egy enkóder-dekóder architektúrába továbbítja, ami jelen esetben egy Swin-transzformer, ami a ViT egy fajtája. Az enkóder-dekóder architektúra által átalakított adatokon ezt követően *patch recovery*t hajt végre, hogy az eredeti felbontást visszakapjuk. A modell célja középtávú (7+ nap) előrejelzések készítése volt, ami eléréséhez egy ún. *hierarchical temporal aggregation* módszert, egy „mohó algoritmust” (*greedy algorithm*) alkalmaztak. Mivel a neurális hálózatok rövid időtávra (1, 3, 6, 24 óra) pontosabban tudnak előrejelezni, a hosszabb távú előrejelzéseket rövidebb távúakból hierarchikusan állítják elő. Például ha 56 órára készítenek előrejelzést, először két 24 órás előrejelzést készítenek. A fennmaradó $56 - 2 \cdot 24 = 8$ órát egy 6 órás és 2 db 1 órás előrejelzéssel fedik le. Ezáltal az előrejelzési hibák kevésbé halmozódnak fel, mintha pl. 56 db 1 órás előrejelzést raknának össze [4].

A következő bemutatott modell a Google által szintén 2023-ban publikált, GNN-alapú GraphCast modellje. A GNN-ek működése fentebb már említésre került. A modell a számításokat egy ún. *multi-mesh*-en – magas felbontású, ikozaéderes gráfon – végzi. A modellben enkóder-processzor-dekóder architektúra található. Az 1 GNN-rétegből álló enkóder 6-szoros iteratív finomítás után az ikozaéder csomópontjait (*node*-jait) a földgömbre vetíti; ezzel létrejönnek $M^0 ... M^6$ rácshálózat, ahol M^0 a legdurvább, M^6 pedig a legfinomabb felbontást jelenti. A teljes *multi-mesh* mind a 7 rácshálózatot magában foglalja. A 16 GNN-réteget magában foglaló processzor a *multi-mesh*-en az információ továbbítását tanulja. A szintén 1 GNN-rétegből álló dekóder a *multi-mesh*-en megtanult jellemzőket visszavetíti a földrajzi fokhálózatra. A *multi-mesh* egyik előnye, hogy – szemben a hagyományos földrajzi fokhálózattal – térben homogén, nincsen pl. a pólusokon *node* felgyülemlés. A másik legnagyobb előnye, hogy a többféle felbontású rácshálózatokat magában foglaló *multi-mesh*-en hatékonyabb az információ továbbítása: egy távoli pontba pl. először a legdurvább M^0-n, majd egyre finomabb rácshálókon halad az információ. A GraphCast modell működését a 1.8. ábra szemlélteti [18].



1.8. ábra. A GraphCast modell működése. Az ábra Lam et al. (2023) [18] cikkéből származik.

A Chen et al. által 2023-ban bemutatott FuXi MLWP-modell három részből áll: a kocka beágyazásból (*cube embedding*), egy U-transzformerből, illetve egy egy teljesen összekötött (*fully connected*) rétegből. A *cube embedding* célja a bemenő sokdimenziós adat idő- és térbeli dimenzióinak, ezáltal redundanciájának csökkentése. Az adatok feldolgozását egy U-transzformer végzi. Az adatdimenzió csökkentését egy alulmintavételező egység, a *Down Block* végzi. Ezt követően 48 egymás utáni Swin-transzformer típusú ViT-ből dolgozza fel az adatokat. Végül az adatok dimenziójának növelését egy felülmintavételező egység, az *Up Block* végzi. A modell felépítését a 1.9. ábra mutaja be [7].



1.9. ábra. A FuXi modell áttekintő szerkezete. Az ábra Chen et al. (2023) [7] cikkéből származik.

Az ECMWF által 2024-ben bemutatott Artificial Intelligence Forecasting System (AIFS) modell több korábban bemutatott MLWP-modell előnyeit ötvözi; egyszerre GNN és transzformer alapú is. Az ERA5 rácshálózatról a processzor alacsonyabb felbontású oktaéderes gráfhálózatára vetítő enkóder és a visszalakítást végző dekóder GNN-transzformer („*GNN attention*”) architektúrával rendelkezik. A processzor tisztán transzformer alapú, 16 db Swin-transzformer rétegből áll. A processzor a rács-

hálózatot alkotó gráf minden pontjának környezetét is figyelembe veszi egy adott levágási (*cut-off*) sugáron belül.

1.5. MLWP-modellek kaotikus tulajdonságai

Azt, hogy megállapítsuk, hogy egy modell tudja-e a kaotikus jegyeket produkálni, legegyszerűbben az előrejelzésben valamilyen kezdeti perturbáció növekedésének vizsgálatával tehetjük meg. Ha a hiba exponenciálisan nő (azaz találunk pozitív Ljapunov-exponenst), a káosz jelen van a predikcióban.

Ezt vizsgálták 2023-ban Selz & Craig kis perturbációval ellátott ensemble (együttes) előrejelzések segítségével. A vizsgált modellek az MLWP-típusú Pangu-Weather és az NWP-típusú ICON modellek voltak; a modell-előrejelzések perturbációra adott válaszát vizsgálták. Azért fontos, hogy a perturbáció kicsi legyen, mert a nagy perturbáció elnyomja a modell-specifikus effektusokat, és az MLWP-modell úgy viselkedik, mint a hagyományos NWP-modellek. Az NWP-modellek alapján várható lenne, hogy a légkör kaotikussága miatt a hozzáadott kis hiba exponenciálisan kezd el nőni, ami az időjárás-előrejelzésnek egy inherens időbeli felső korlátot ad („pillangó-hatás"). Ezzel szemben Selz & Craig azt tapasztalták, hogy a Pangu-Weather nem képes reprodukálni ezt a kezdeti exponenciális hibanövekedést, amivel egy hamis biztonságérzetet ad a hosszútávú időjárás-előrejelzések megbízhatóságára [30].

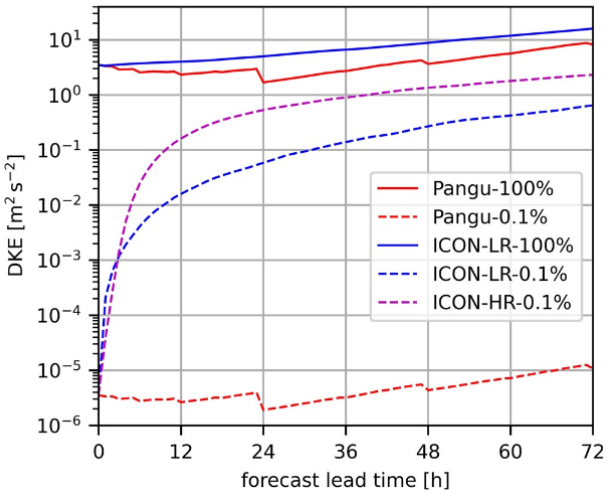
Vizsgálatuk során kis- és nagy felbontású rácshálózatot is alkalmaztak. A nagy felbontású rácson (2,5 km) a konvekció – a légkör egyik legkevésbé lineáris folyamata – is megfigyelhető legyen. A vizsgálat esettanulmány-jellegű, 2021. június 26. 00 UTC inicializációs idejű előrejelzéseket használtak fel. Az időpont-választás oka, hogy ekkor Észak-Amerika felett – nyár lévén – nagyon jelentős konvekciós folyamatok zajlottak; azonban eredményeiket az egész Földre átlagolva adták meg [30].

A hibanövekedés számszerűsítésére egy ilyen célra gyakran használt mennyiséget, a 300 hPa-on számolt kinetikus energia-különbséget (*Difference Kinetic Energy, DKE*) alkalmazták:

$$\mathrm{DKE} = \mathrm{Var}(u) + \mathrm{Var}(v),$$

ahol u és v a horizontális szélkomponensek [30].

A kutatók kis- és nagyobb perturbációkat is végeztek; eredményeiket a 1.10. ábra foglalja össze.



1.10. ábra. Az ICON és Pangu-Weather (*Pangu*) nagy (*100%*) és kicsi (*0.1 %*) perturbációkra adott válaszai a DKE növekedésén keresztül bemutatva. A *HR* a nagy felbontást (2.5 km), a *LR* az alacsony felbontást (20 km) jelent. Az ábra Selz & Craig (2023) [30] cikkéből származik.

A nagy perturbáció során alátámasztásra került a várakozásuk, hogy az elnyomja az MLWP-modell jellegzetességeit: az erősen perturbált Pangu-Weather (*Pangu-100%*) hasonlóan viselkedett, mint az

erősen perturbált ICON (*ICON-LR-100%*). A kicsit perturbált ICON (*ICON-0.1%*) esetében is az NWP-modellektől elvárható eredményre jutottak: a hiba nagyon gyorsan kezdett nőni, míg szaturációba nem került (48 óra után a hibanövekedési ütem kb. megegyezett az erősen perturbált ICON-éval). Ha az alacsonyabb felbontású, kicsit perturbált modellt (*ICON-LR-0.1%*) a magasabb felbontásúhoz (*ICON-HR-0.1%*) hasonlítjuk, megfigyelhető, hogy az alacsonyabb felbontású alulbecsli a hibát már néhány óra elteltével. Ennek oka az lehet, hogy a kis felbontás miatt nincsenek megfelelően reprezentálva a hibához jelentősen hozzájáruló nemlineáris konvektív folyamatok [30].

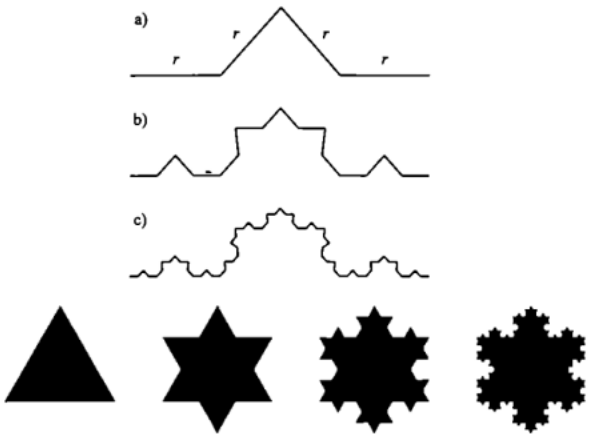
A kicsit perturbált Pangu-Weather modell hibanövekedésének időbeli lefutása nagyon hasonló az erősebben perturbálthoz; az eltolás a hibában a perturbáció mértékével arányos. A Pangu-Weather az ICON modellhez képest alulbecsli a hibát és konstans hibanövekedést mutat az exponenciális helyett, ami – helytelenül – sokkal hosszabb távú előrejelezhetőséget sugall [30].

Azonban a fent említett vizsgálat elvégzéséhez – tekintve, hogy az ensemble előrejelzések sok tagból állnak – rendkívül magas számítási kapacitásra van szükség. Selz & Craig pl. az ECMWF Atos nevű szuperszámítógépét használták. A Pangu-Weather kísérletek 16, az alacsony felbontású ICON-kísérletek 2900, a magas felbontású ICON-kísérletek pedig 1300000 számítási órába kerültek egyenként [30].

Ennél olcsóbb módszerek lehetnek az előrejelzési idősorban való kaotikus viselkedés észlelése, vagy trajektóriamodellezés.

Az előrejelzési idősorban való kaotikus viselkedés észlelésére felhasználható módszerekkel foglalkozik Pánis et al. 2020-as cikke [28].

A kaotikus rendszereket fázistérben (pl. sebesség-kitérés koordináta-rendszer) ábrázolva komplex, de rendezett, fraktálszerű alakzatot kapunk. A fraktálok olyan geometriai alakzatok, melyek kerülete és felülete nincs definiálva és önhasonlóak; ezt szemlélteti a 1.11. ábrán feltüntetett híres példa, a Koch-görbe, melynek területe véges marad ugyan, de kerülete a végtelenhez tart [34].



1.11. ábra. A Koch-görbe szerkesztése és fraktálszerkezete. Az ábrák Tél & Gruiz Kaotikus dinamika című tankönyvéből (2002) származnak [34].

A fraktálokat fraktáldimenzióval szokás jellemezni, ami síkbeli (térbeli) alakzatoknál egynél (kettőnél) nagyobb, de kettőnél (háromnál) kisebb tört vagy irracionális szám; a dimenzió nagysága az alakzat tagoltságával arányos. Fedjük le ezeket az alakzatokat ε karakterisztikus méretű dobozokkal (*box*-okkal). Míg pl. egy hagyományos síkbeli alakzat lefedéséhez ε^{-2}-el arányos az alakzat egyre finomabb lefedéséhez szükséges dobozok száma, addig fraktáloknál a kitevő egy nem egész szám, a fraktáldimenzió lesz:

$$N(\varepsilon) \propto \varepsilon^{-D_0},$$

ahol $\varepsilon \to 0$, N az alakzat lefedéséhez szükséges minimális számú doboz, D_0 pedig a fraktáldimenzió.

Átrendezve:

$$D_0 = \lim_{\varepsilon \to 0} \frac{\ln N(\varepsilon)}{\ln 1/\varepsilon}$$

adja meg a fraktáldimenziót. A box-counting módszer arra épül, hogyha tudunk ilyen fraktáldimenziót találni, akkor a vizsgált idősor kaotikus jeleket mutat [34, 28].

Másik módszer az idősor-adatokban a káosz észlelésére a korrelációs dimenzió (D_2) vizsgálata. A korrelációs dimenzió kiszámítása során megszámoljuk, hogy hány pontpár ($C(\varepsilon)$) van egymáshoz közelebb, mint egy nagyon kicsi ε küszöbérték:

$$D_2 = \lim_{\varepsilon \to 0} \frac{\ln C(\varepsilon)}{\ln \varepsilon}.$$

Ha találunk korrelációs dimenziót, az idősor kaotikus [28].

Következő módszer a Ljapunov-exponens keresése. Ha a kaotikus attraktor egy **r** pontja körül két közeli pontból indítunk részecskéket, távolságuk a lépések n számának növelésével exponenciálisan nőni fog:

$$\Delta r_n = \Delta r_0 e^{\bar{\lambda} n},$$

ahol Δr_0 a kezdeti (kicsi) távolságuk, $\bar{\lambda}$ pedig a fázistérhez rendelhető átlagos Ljapunov-exponens. Kaotikus rendszerekben $\bar{\lambda} > 0$. Ha az idősorban sikerül pozitív Ljapunov-exponenst találni – pl. egyenesillesztéssel –, akkor a rendszer, ahonnan az idősor származik, kaotikus [28].

A gépi tanulást a kaotikus viselkedés detektálására is használhatjuk. Alkotható olyan modell, amely a kaotikus minták felismerésére van tanítva, így az ember számára nehezen felismerhető vagy észrevétlenül maradt mintázatokat is képes felismerni [28].

A kaotikus jelek detektálására használhatóak lagrange-i trajektória modellek is: szimulálható segítségükkel, hogy a légkör egy térfogatdarabja (pl. egy szennyezés) hogyan változtatja térfogatát, növeli időben exponenciálisan a szálainak a hosszát, majd áll rá a kaotikus attraktorra [14].

A terjedési modellek célja, hogy a meteorológiai viszonyok (szélvektor) ismeretében modellezzék, hogy a légkörben egy részecske hogyan terjed. A terjedési modellek időjárás-előrejelző modellekkel vannak meghajtva, azok szélviszony-előrejelzései szolgáltatják a széladatokat a részecske mozgásának modellezéséhez. A terjedési modellekkel figyelembe lehet venni a felszínközeli viszonyokat, mint a súrlódás, azonban az bonyolulttá teszi a modellt. Ha alacsonyabb nyomású izobárszinteken vizsgáljuk a részecskék terjedését, dominánsan csak a szél fogja befolyásolni a részecske terjedését, így a súrlódás elhanyagolhatóvá válik.

A szimulált trajektóriák felhasználásával is ki lehet mutatni a káosz jelenlétét, legegyszerűbben a topologikus entrópia (h) segítségével tehető ez meg. A mennyiség jellemzi egy kezdetben L_0 hosszú fonaldarab megnyúlását:

$$L(t) = L_0 \cdot e^{ht} \quad (t \gg 1/h),$$

tehát a mozgás bonyolultságával van kapcsolatban: minél nagyobb h, annál bonyolultabb lesz a mozgás (jobban megnyúlik a kezdeti fonaldarab). Ha $h > 0$, a mozgás kaotikus. A topologikus entrópia becslése sok részecske pályájának nyomon követésével lehetséges [15].

2. Adat, módszer

Vizsgálataim során 2 dimenziós trajektóriamodellt hajtottam meg 2026. június 1-én UTC szerint 0 órakor készült ECMWF-IFS, illetve ECMWF-AIFS szél-előrejelzésekkel. Az előrejelzések középtávúak (360 órára előre készülnek el 6 órás lépésekkel), determinisztikusak, és jelentős számú izobárszintre (1000, 925, 850, 700, 600, 500, 400, 300, 250, 200, 150, 100, 50 hPa) elkészülnek $0,25° \times 0,25°$ globális térbeli felbontással.

2.1. A trajektóriamodell

Trajektóriamodellnek egy, a témavezetőm által biztosított, Python nyelven írt modellt vettem alapul. Ezt jelentősen átalakítva, illetve további funkciókkal bővítve használtam fel.

A modell bemenetként várja:

- Szélességi kör intervallum mintavételezési sűrűséggel, ahonnan a részecskéket indítjuk (*ndarray adattípus, tetszőleges dimenzió*).
- Hosszúsági kör intervallum mintavételezési sűrűséggel, ahonnan a részecskéket indítjuk (*ndarray adattípus, szélességi körök array-évl megegyező dimenzió*).
- Eredeti ECMWF előrejelzések indítási ideje (*yyyymmdd formátumban, int adattípus*).
- Előrejelzési időtartam (*értéke legfeljebb 360, int adattípus*).
- Vizsgált izobárszint (*értéke az ECMWF által használt főizobárszintek valamelyike lehet, int adattípus*).

Mivel a modellelőrejelzések csak 6 óránként állnak rendelkezésre, a trajektóriamodell lineáris interpolációt végez a köztes időpillanatok szélsebességének kiszámítására, amivel egy időben folytonosan változó szélsebesség-mezőt hoz létre.

Az elengedett részecskék trajektóriájának kiszámításához a következő differenciálegyenlet-rendszert szükséges megoldani minden részecskére:

$$\frac{d\lambda}{dt} = u \cdot C \cdot \frac{1}{\cos\varphi},$$

$$\frac{d\varphi}{dt} = v \cdot C,$$

ahol u a keleti (zonális)-, v pedig az északi (meridionális) szélkomponens m/s-ban; C egy váltószám, ami a m-t °-ba váltja át ($C = \frac{180°}{\pi \cdot R}$, ahol $R = 6371000$ m a Föld sugara); λ a részecske (keleti) hosszúsági koordinátája, φ az (északi) szélességi koordinátája; t pedig a szimulációs idő másodpercben. A 0-val való osztást úgy akadályozzuk meg, hogy a szélességi köröket csak $-89,9°$ és $89,9°$ között vesszük. A differenciálegyenlet-rendszert az elterjedt Runge-Kutta 5(4) rendű módszer segítségével integráltam numerikusan. A Runge-Kutta módszer adaptív időlépésekkel dolgozik. Az esetlegesen fellépő túl nagy időlépés alkalmazását úgy akadályoztam meg, hogy a maximális lépésközt 10 percre állítottam. A relatív és abszolút hibatoleranciát is 10^{-3}-nak vettem.

A szimulációkkal fő célom topologikus entrópia meghatározása volt, amihez a részecskék által kifeszített fonal hosszának időbeli változását szükséges vizsgálni. Azonban ha túl messzire kerül egymástól két szomszédos részecske, a köztük lévő, koordinátáik felhasználásával egyszerűen számítható, légvonalbeli távolság nem fog megegyezni a köztük lévő fonaldarab hosszával. Ennek kiküszöbölésére ha két szomszédos részecske egymástól több, mint 20 km távolságra került, beszúrtam egy részecskét közéjük. A dinamikus részecskebeszúrással előállított trajektóriákat kezdetiérték-vektor felülírással ciklusban léptetett Runge-Kutta módszerrel integráltam.

Az ilyen módon előállított, megfelelően sűrű részecskehálózatban jó közelítés a szomszédos részecskék közti fonaldarab hosszára a légvonalbeli d távolságuk, melyet a Haversine-formulával számítottam:

$$d = R \cdot 2 \cdot \arcsin\sqrt{\sin\left(\frac{\Delta\varphi}{2}\right)^2 + \cos(\varphi_1) \cdot \cos(\varphi_2) \cdot \sin\left(\frac{\Delta\lambda}{2}\right)^2},$$

ahol (φ_1, λ_1) és (φ_2, λ_2) a két részecske koordinátája, $\Delta\varphi$ szélességi radián különbségük, $\Delta\lambda$ hosszúsági radián különbségük, $R = 6371000$ m pedig a Föld sugara.

A trajektóriamodell futtatása 8 magos (16 szálas) AMD Ryzen 7 2700X processzor alapú számítógépen történt. A részecskebeszúrást végző metódussal ellátott modell jelentősen megnövekedett lineáris algebrai számítási terhelést jelentett a részecskék megugró száma miatt. A futási időt a NumPy által támogatott többszálú végrehajtás engedélyezésével csökkentettem.

2.2. Kaotikus viselkedés számszerűsítése

A modellezett trajektóriák felhasználásával topologikus entrópiát számoltam. Ehhez a szimuláció minden időlépésében szükséges kiszámolni a részecskéket képzeletben összekötő, egyre bonyolultabb alakot felvevő fonal hosszát. Ez úgy tehető meg, hogy az adott időlépésben a részecskék koordinátáinak ismeretében kiszámolom, milyen messze vannak egymástól a szomszédos részecskék, és ezeket a távolságokat összeadom. Ha a részecskék elég sűrűen helyezkednek el, ezzel a módszerrel viszonylag pontosan megkapható a fonal megnyúlásának időfüggése, a kapott adatokra való illesztéssel pedig egyszerűen meghatározható a h topologikus entrópia. Az elég sűrű elhelyezkedést 20 km-es távolságküszöbbel dinamikus részecskebeszúrással biztosítottam.

A rendelkezésre álló adatok $0,25° \times 0,25°$ felbontásúak, ami kb. 27 km $\times$ 27 km-es felbontást jelent. Ez trajektóriák modellezésekor meglehetősen durva felbontásnak számít, a szakirodalomban ennél jóval finomabb felbontást – pl. 300-600 m – használnak [15]. A részecskéket számítási kapacitásokat figyelembe véve egymástól $0,05°$-ra indítottam, ami kb. 5,4 km-t jelent. A modell minden lépésben térbeli lineáris interpolációval határozza meg a szélsebességet a részecskék pillanatnyi pozíciójában.

A fonal hosszát szemilogaritmikus diagramon ábrázolva az idő függvényében egy egyenes illesztésével, az egyenes meredekségeként lehet meghatározni a topologikus entrópiát.

3. Eredmények

A modellt ECMWF-IFS, illetve ECMWF-AIFS szélelőrejelzésekkel is meghajtottam.A vizsgálatokat több izobárszinten (850, 700, 500 hPa) végeztem, 168 órás előrejelzési időtávra. Az előrejelzési időtáv megválasztása azért történt így, mert ez már elég hosszú idő ahhoz, hogy reprezentatív lenyomatot kaphassunk a légkör folyamatairól. Emellett elég rövid ahhoz, hogy a szimulációknak – a jelentősen megnövekvő részecskeszám miatt – ne teljen túl sok időbe lefutniuk.

3.1.

3.2. Szimulációs idők összehasonlítása

4. Köszönetnyilvánítás

A kutatás az NKKP STARTING 153030 projekt keretében készült.

Hivatkozások

[1] Aihara, K. et al. Chaotic neural networks. *Physics Letters A*, 144(6):333–340, March 1990. https://www.sciencedirect.com/science/article/pii/037596019090136C.

[2] Alzubi, J. et al. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018. https://doi.org/10.1088/1742-6596/1142/1/012012.

[3] Anusree, M. et al. Understanding chaotic neural networks: A comprehensive review. *Nonlinear Dynamics*, 113(19):25389–25404, October 2025. https://doi.org/10.1007/s11071-025-11503-7.

[4] Bi, K. et al. Accurate medium-range global weather forecasting with 3D neural networks. *Nature*, 619(7970):533–538, July 2023. https://www.nature.com/articles/s41586-023-06185-3.

[5] Biswas, H. R. et al. Chaos Theory and Its Applications in Our Real Life. 2018.

[6] Bonavita, M. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. _eprint: https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377, https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL107377.

[7] Chen, L. et al. FuXi: a cascade machine learning forecasting system for 15-day global weather forecast. *npj Climate and Atmospheric Science*, 6(1):190, November 2023. https://www.nature.com/articles/s41612-023-00512-1.

[8] Choi, R. Y. et al. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020. https://doi.org/10.1167/tvst.9.2.14.

[9] Crook, N. et al. A Novel Chaotic Neural Network Architecture. In *ESANN'2001 proceedings - European Symposium on Artificial Neural Networks*, pages 295–300, Bruges, Belgium, 2001. D-Facto public.

[10] de Burgh-Day, C. O. et al. Machine learning for numerical weather and climate modelling: a review. *Geoscientific Model Development*, 16(22):6433–6477, November 2023. https://gmd.copernicus.org/articles/16/6433/2023/.

[11] Dosovitskiy, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, June 2021. arXiv:2010.11929 [cs.CV], http://arxiv.org/abs/2010.11929.

[12] Guibas, J. et al. Adaptive Fourier Neural Operators: Efficient Token Mixers for Transformers, March 2022. arXiv:2111.13587 [cs.CV], http://arxiv.org/abs/2111.13587.

[13] Géron, A. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, Inc., Sebastopol, California, 2017.

[14] Haszpra, T. *A RePLaT modell és alkalmazása légköri szennyeződések terjedésének vizsgálatára*. PhD thesis, Eötvös Loránd Tudományegyetem, 2014. http://hdl.handle.net/10831/9274.

[15] Haszpra, T. et al. Ensemble-based analysis of the pollutant spreading intensity induced by climate change. *Scientific Reports*, 9(1):3896, March 2019. https://www.nature.com/articles/s41598-019-40451-7.

[16] Hung, N. Q. et al. An artificial neural network model for rainfall forecasting in Bangkok, Thailand. *Hydrology and Earth System Sciences*, 13(8):1413–1425, August 2009. https://hess.copernicus.org/articles/13/1413/2009/hess-13-1413-2009.html.

[17] Kelleher, J. D. *Deep Learning*. The MIT Press, Cambridge, Massachusetts, September 2019.

[18] Lam, R. et al. GraphCast: Learning skillful medium-range global weather forecasting, August 2023. arXiv:2212.12794 [cs.LG], http://arxiv.org/abs/2212.12794.

[19] Lecun, Y. et al. Convolutional networks for images, speech, and time series. 1995.

[20] Lee, A. et al. Machine Learning Has Arrived! *Ophthalmology*, 124(12):1726–1728, December 2017. https://linkinghub.elsevier.com/retrieve/pii/S0161642017315634.

[21] Medsker, L. R. et al. Recurrent Neural Networks. 2001.

[22] Mitchell, T. M. The Discipline of Machine Learning. 2006.

[23] Moldovan, G. et al. An update to ECMWF's machine-learned weather forecast model AIFS, September 2025. arXiv:2509.18994 [physics], http://arxiv.org/abs/2509.18994.

[24] Moor, J. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27(4):87–87, December 2006. https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1911.

[25] Ortiz, E. L. et al. Exploring low-resource weather forecasting with echo state network-based architectures and satellite data. *Knowledge-Based Systems*, 323:113692, July 2025. https://www.sciencedirect.com/science/article/pii/S0950705125007385.

[26] Pathak, J. et al. FourCastNet: A Global Data-driven High-resolution Weather Model using Adaptive Fourier Neural Operators, February 2022. arXiv:2202.11214 [physics], http://arxiv.org/abs/2202.11214.

[27] Purwono, P. et al. Understanding of Convolutional Neural Network (CNN): A Review. *International Journal of Robotics and Control Systems*, 2(4):739–748, 2022. https://pubs2.ascee.org/index.php/IJRCS/article/view/888.

[28] Pánis, R. et al. Detection of chaotic behavior in time series, December 2020. arXiv:2012.06671 [physics.comp-ph], http://arxiv.org/abs/2012.06671.

[29] Scarselli, F. et al. The Graph Neural Network Model. *IEEE Transactions on Neural Networks*, 20(1):61–80, 2008. http://ieeexplore.ieee.org/document/4700287/.

[30] Selz, T. et al. Can Artificial Intelligence-Based Weather Prediction Models Simulate the Butterfly Effect? *Geophysical Research Letters*, 50(20):e2023GL105747, 2023. _eprint: https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL105747, https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL105747.

[31] Sharifani, K. et al. Machine Learning and Deep Learning: A Review of Methods and Applications. 10(07), 2023. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723.

[32] Sharkawy, A.-N. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020. https://univ-brest.hal.science/hal-03114305.

[33] Shi, J. et al. Deep Learning and Foundation Models for Weather Prediction: A Survey, January 2025. arXiv:2501.06907 [cs.LG], http://arxiv.org/abs/2501.06907.

[34] Tél, T. et al. *Kaotikus dinamika*. Nemzeti Tankönyvkiadó Rt., Budapest, 2002.

[35] Vaswani, A. et al. Attention is All you Need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.