

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. A mesterséges intelligencia és gépi tanulás	2
1.3. Kaotikus neurális hálózatok	8
1.4. Gépi tanulás alapú időjárás-előrejelző modellek	9
1.5. MLWP-modellek kaotikus tulajdonságai	9

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszer, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [20]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; ECMWF-AIFS, 2024; illetve néhány ensemble modell: Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*Mean Squared Error, MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre. A modellfejlesztők a valósághú predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt [18].

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [5]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanul teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [23]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. A mesterséges intelligencia és gépi tanulás

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project*

on Artificial Intelligence). Felvetett elvük azon alapult, hogy „a tanulás minden aspektusa, vagy az intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet” [19, 6]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik; ezt nevezzük gépi tanulásnak [2].

Az első gépi tanulás alapú technológia az 1990-es években lett népszerű, amikor megjelentek az elektronikus levelezőrendszerekben a spamfilterek: a szűrő felhasználói bejelentésekből származó adatokon lett betanítva, megtanulva, hogy milyen jellemzői vannak egy spam e-mailnek. Az ezt követő évtizedekben egyre több gépi tanulás alapú technológia jelent meg, gondolhatunk itt a mindennapokban gyakran használt beszédfelismerő eszközökre vagy a közösségi média tartalomajánló algoritmusaira [11]. A gépi tanulást 1959-ben Arthur Samuel amerikai informatikus így definiálta [15]:

A gépi tanulás képessé teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket.

Egzaktabb definíciót nyújt Tom Mitchell szintén amerikai informatikus megfogalmazása [17]:

Egy számítógépes program valamilyen T feladat elvégzése érdekében – melynek sikerességét valamely P teljesítményt értékelő mérőszám jellemzi – E tapasztalatból tanul, ha a T elvégzése során nyújtott teljesítménye P mérőszámmal mérve az E tapasztalat megszerzésével javul.

A gépi tanulás olyan problémák megoldásában lehet rendkívül hasznos, amik túl komplexek, vagy nem ismert algoritmikus megoldásuk. Ha megnézzük, hogy a gép milyen mintázatokat ismert fel vagy kapcsolatokat tanult meg, akkor az ember is új, addig még fel nem fedezett korrelációkat vehet észre, ami által a megértésünk javulhat, ezt nevezzük adatbányászatnak (*data mining*). A példák, tapasztalatok, amik segítségével a gép tanul, a tanító adathalmaz (*training set*) részét képezik ezek a minták (*sample*) [11].


A gépi tanulási rendszereket csoportosíthatjuk aszerint, hogy humán felügyelet alatt van-e tanítva (felügyelt – *supervised*, felügyelet nélküli – *unsupervised*, félig felügyelt – *semisupervised*, megerősítéses – *reinforcement* tanulás); menet közben tud-e fokozatosan tanulni (*online* és *batch* tanulás); illetve hogy az új adatokat a már ismertekhez hasonlíttja (példa alapú – *instance-based* tanulás) vagy a tanító adathalmazban mintázatokat ismer fel, és ez alapján előrejelzést tud adni (modell alapú – *model-based* tanulás). A legfontosabb fogalmak a fentiek közül a felügyelt, felügyelet nélküli, illetve megerősítéses tanulás [11].

A felügyelt tanulás során a tanító adathalmaz tartalmazza a kívánt kimenetet / helyes megoldást (ezt nevezzük címkének – *label*). Példa lehet erre, hogy szeretnénk betanítani egy modellt, hogy korábbi eladási adatokat ismerve jelezze előre, mennyit ér egy eladásra szánt autó. Az autónak a tulajdonságai (*feature*; mint a kora, megtett km, márka stb.) adottak. Az előrejelezni kívánt numerikus mennyiséget hívjuk *predictor*-nek vagy *target*-nek (jelen esetben ez az autó ára). Az előrejelzéshez használt algoritmus többféle lehet, legismertebb példái a lineáris regresszió és a neurális hálózat architektúrák. Felügyelet nélküli tanulás során a tanító adathalmaz nincsen felcímkézve, a modell maga tanulja meg a jellemzőket elkülöníteni. Legismertebb példa a klaszterezés (*clustering*), amikor a modell a vizsgált adatokat a megfigyelt tulajdonságaik alapján osztályozza. Megerősítéses tanulás esetén a tanuló rendszert (az ágens – *agent*) megfigyeli a környezetét és a kialakított irányelvnek (*policy*) megfelelően tetteket hajt végre. A tetteiért jutalmat (*reward*) vagy büntetést (*penalty*) kap. Az ágens célja a jutalom maximalizálása, ami érdekében iteratívan frissíti az irányelvét [11].

A gépi tanulás alapú modellek problémái legtöbbször a tanító adatból származnak: gondot jelent a nem megfelelő mennyiségű, minőségű, nem elég reprezentatív, vagy irreleváns adat. Ha az adat túl zajos, felléphet a túlillesztés (*overfitting*), ami azt jelenti, hogy a modell túl komplex a feladathoz. Ha

a modell túl egyszerű, azt alulillesztésnek (*underfitting*) nevezzük. Az elkészült gépi tanulás alapú modelleket ezen hibák kiszűrése érdekében validálják, melynek népszerű eszköze az igazságmátrix (*confusion matrix*) [11].

A gépi tanulás hagyományosan statisztikai módszerek segítségével történik a megfigyelt adatok alapján. A gépi tanulás múlt században megalkotott, és az utóbbi évtizedekben elterjedt technikája egészen más megközelítést kínál; ezek a mesterséges neurális hálózatok (*Artificial Neural Network, ANN*). Az ANN-ek segítségével az adatbázisban fennálló komplex kapcsolatok is felismerhetők [24]. Az ANN-eket 1943-ban mutatta be Warren McCulloch amerikai neurofiziológus és Walter Pitts számítógépes idegtudós. Az ANN-t mesterséges neuronok alkotják, melyek működését a biológiai neuronok ihlették, melyet az 1. ábra mutat be.



1. ábra. A biológiai neuron szerkezete. Az ábra Géron *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (2017) [11] könyvéből származik.

A biológiai neuron (idegsejt) az agykéregben előforduló sejt, melynek főbb részei a sejttest (*cell body*), a dendritok (*dendrite*), illetve a nagyon hosszú nyúlványa, az axon. Az axon telodendronokra bomlik, melyek csúcán kis szinapszisok találhatóak, melyek a dendritokba tudnak kapcsolódni és a neuronok kis elektromos impulzusokkal történő kommunikációjáért felelősek. Ha a neuron adott idő alatt elég jelet kap, maga is aktiválódik és jeleket ad le. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt [6]. Az agyban a neuronok egymás utáni rétegekbe vannak rendeződve, így lesz képes az emberi agy komplex feladatok elvégzésére is [11].

Az ANN rétegebe rendeződött neuronokból áll. A rétegekben csomópontok vannak, az információ feldolgozásáért felelős mesterséges neuronok pedig kapcsolatokon keresztül kommunikálnak egymással [25]. A csomópontok a biológiai neuron sejttestének feleltethetők meg, a kapcsolatok pedig hasonlóan működnek, mint az axonok és dendritok. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [6].


A McCulloch és Pitts által megalkotott ANN kijelentéslogikán alapult. A neuronok egy vagy több bináris (*on/off* típusú) bemenetet (*input*) fogadtak, és egyetlen kimenetet (*output*) adtak. A biológiai neuronok aktiválódását úgy imitálták, hogy a mesterséges neuron csak akkor adott kimenetet, ha a kapott bemenetek száma elért egy bizonyos értéket.

Az egyik legegyszerűbb neurális hálózat a Perceptron, melyet 1957-ben Frank Rosenblatt mutatott be. Úgynevezett küszöb logikai egységek (*Threshold Logic Unit, TLU*) a mesterséges neuronok, az input és output értékek pedig numerikusak; minden input – fontosságának megfelelően – súlyozva van. A súlyozott bemenetek mellett egy b konstans értéket felvevő elfogultság (*bias*) is hozzáadásra szokott kerülni. A TLU egy súlyozott összeget számol, majd egy nemlineáris aktivációs függvényt hatar az eredményre, és ezt adja outputnak. Az aktivációs függvényre azért van szükség, hogy a lineárisnál bonyolultabb kapcsolatokat is képes legyen megtanulni az ANN. Aktivációs függvény lehet pl. a Heaviside-féle egységfüggvény, ReLu (*REctified Linear Unit*, ami a negatív értékeket lenullázza), de

gyakran valamilyen szigmoid függvényt alkalmaznak a célra, mint a tangens hiperbolikus vagy a logisztikus függvény. A mesterséges neuron működését az alábbi egyenlet foglalja össze:

$$s_j = \sum_{i=1}^m w_{ij} \cdot x_i + b_j; \quad \hat{y}_j = \varphi(s_j),$$


ahol x_i az input, b_j a bias, w_{ij} a súlymátrix, s_j a súlyozott összeg, φ az aktivációs függvény, $\hat{y}_j$ pedig az output. A fentebb leírt mesterséges neuron működését mutatja be a 2. ábra. [25, 11, 13].



2. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [25] cikkéből származik (CC BY-NC 4.0).

Egyszeres neuronréteg azonban csak egyszerűbb feladatok elvégzésére alkalmazható; ha bonyolultabb problémákat szeretnénk megoldani, több rétegre van szükség. A kettőnél több rétegből álló ANN-t mély neurális hálózatként (*Deep Neural Network, DNN*) nevezzük. Ennek legegyszerűbb példája a többrétegű Perceptron (*Multilayer Perceptron, MLP*), ami több rétegnyi TLU-ból áll, melyeket rejtett rétegeknek (*hidden layers*) nevezünk. Minden réteg teljesen hozzá van kapcsolva a szomszédos réteghez (*Fully Connected, FL*) [11].


A bonyolultabb feladatok elvégzésére tehát mélytanulások (*Deep Learning, DL*) technológiák alkalmasak. Mélytanulási architektúra többek között a konvolúciós neurális hálózat (*Convolutional Neural Network, CNN*), rekurrens neurális hálózat (*Recurrent Neural Network, RNN*), a gráfolapú neurális hálózat (*Graph Neural Network, GNN*), a transzformer architektúra (*Transformer*), vagy a Vision Transformer [26]. Az időjárás-előrejelzésben használt MLWP-modellek áttekintését mutatja a 3. ábra.



3. ábra. Az MLWP-modellek áttekintése. Az ábra Shi et al. (2025) [26] cikkéből származik.

Ahogy az ábrán is látható, az MLWP-modelleknek alapvetően három fajtája van. Legelterjedtebbek az általános célú nagy modellek (*General-Purpose Large Models*), melyek többféle időjárási paraméter globális előrejelzésére alkalmasak. Az operatív időjárás-előrejelzésben kevésbé elterjedtebbek a domén specifikus modellek (*Domain-Specific Models*, melyekkel regionális előrejelzést lehet készíteni egyetlen változóra), illetve az alapmodellek (*Foundation Models*, melyekkel még további finomhangolás, specifikus feladathoz adaptálás lehetséges). Az is megfigyelhető, hogy az utóbbi években a CNN és RNN alapú időjárás-előrejelző modellek háttérbe szorultak a GNN és transzformer architektúrájú modellek mellett.

A CNN architektúrát LeCun et al. mutatta be 1995-ben [14]. Az architektúra struktúrált rácsadatok, mint pl. a képek feldolgozására alkalmas; klasszikusan a gépi látás területén (pl. képosztályozás) CNN modelleket használnak [26]. A CNN-nek négy rétege van (konvolúciós réteg – *convolutional layer*, gyűjtőréteg – *pooling layer*, teljesen összekötött réteg – *fully connected layer* és a nemlineáris réteg – *nonlinearity layer*), melyeket a 4. ábra szemléltet. A rétegek szerepét egy képosztályozási feladaton keresztül mutatom be.



4. ábra. A CNN szerkezete. Az ábra Purwono et al. (2022) [21] cikkéből származik.

A CNN az inputként kapott képet egy mátrixként látja, ahol a mátrix minden eleme az adott pixel

fényintenzitását reprezentálja. A konvolúciós réteg (*convolutional layer*) a képekből a jellemzőket (*feature*, pl. élek, textúrák, minták) nyeri ki. A gyűjtőréteg (*pooling layer*) konvolúciós rétegeket kapcsol össze; szerepe a paraméter- és ezáltal számítási teher csökkentése a konvolúciós réteg kimeneteinek alulmintavételezett reprezentáció készítésével. A teljesen összekapcsolt réteg (*fully connected layer*, más néven konvolúciós output réteg – *convolutional output layer*) bemenete az utolsó pooling réteg. Az adatot a következő rétegbe továbbítás előtt vektorra lapítja. Az utolsó réteg a nemlineáris réteg vagy aktivációs függvény (*nonlinearity layer / activation function*); ez a réteg adja meg a neurális hálózat végső kimenetét, a választ az adott feladatra [21].

Az RNN-eket 2001-ben mutatta be Medsker & Jain [16], mint időfüggő vagy szekvenciális adatokkal kapcsolatos feladatok (pl. idősor-előrejelzés) végzésére alkalmas architektúrákat. A modell rekurrens módon tanul a kapott adatsorozatból egy belső rejtett állapot segítségével, ami tartalmazza a korábbi rejtett állapotokat és az aktuális bemenetet. A tanulás folyamatát az alábbi egyenletek írják le:

$$h_t = \sigma(\mathbf{W}_x x_t + \mathbf{W}_h h_{t-1} + b_h); \quad y_t = \sigma(\mathbf{W}_y h_t + b_y),$$

ahol a t -edik időpillanatban h_t a rejtett állapot, x_t az input, y_t az output; $\mathbf{W}_x, \mathbf{W}_h, \mathbf{W}_y$ súlymátrixok, b_h, b_y bias-ok, σ pedig az aktivációs függvény. A CNN-nél és RNN-nél sokkal fontosabb architektúrák azonban az időjárás-előrejelzésben a GNN-ek és a transzformer alapú neurális hálózatok [26].

A GNN-t 2008-ban mutatták be Scarselli et al. [22]. Az architektúra $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ $\mathcal{V}$ csúccsal és $\mathcal{E}$ éllel rendelkező gráf szerkezetű adatok feldolgozására alkalmas, ahol a csúcsok a vizsgált dolgokat, az élek pedig a köztük fennálló kapcsolatokat reprezentálják. Ha a GNN a tér- és időbeli függőségeket is jól modellezi, tér-idő GNN-ekről (*Spatio-temporal GNN, ST-GNN*) beszélünk, melyeket a $\mathcal{G}_t = (\mathcal{V}, \mathcal{E}, t)$ jelöléssel szoktak illetni. Itt a csúcsok és az élek térbeli kapcsolatokat írnak le; a vizsgált dolog i térbeli helyen és t időpillanatban felvett vektorát a v_t^i vektor reprezentálja. A térbeli függőségek figyelembevétele az egyes csomópontok szomszédjaikkal való kommunikációján (*message passing*) keresztül valósul meg. Az időbeli kapcsolatokat szekvenciális modellekkel (mint az RNN) lehet figyelembe venni. A csomópontok h_t^i rejtett állapotai a v_{t+1}^i üzenetvektorokkal kerülnek frissítésre az alábbi módon:

$$v_{t+1}^i = \sum_{j \in N(i)} M_t(h_t^i, h_t^j, e_{ij}); \quad h_{t+1}^i = \sigma(h_t^i, v_{t+1}^i),$$

ahol $N(i)$ az i -edik csomópont szomszédjai, M_t az üzenetküldő függvény, e_{ij} pedig az i -edik és j -edik csomópont közti élet jellemzi [26].

Az utóbbi évek legnépszerűbb mesterséges intelligencia-alapú modelljeinek alapjai a transzformer architektúrák. 2017-ben jelent meg Vaswani et al. a transzformer neurális hálózatokat bemutató azóta már nagyon híressé vált cikke, az „Attention Is All You Need” [27]. Az architektúra a figyelem mechanizmus (*attention mechanism*) alapján működik; szekvenciális lépések közbeiktatása nélkül képes az adatban fennálló kapcsolatokat megragadni. A figyelem mechanizmus az alábbiak szerint írható le:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \mathbf{V},$$


ahol d_k a $\mathbf{K}$ kulcsmátrix (*key matrix*) dimenziója, $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$ a lekérdezési mátrix (*query matrix*), $\mathbf{K} \in \mathbb{R}^{m \times d_k}$ a kulcsmátrix, $\mathbf{V} \in \mathbb{R}^{m \times d_v}$ az értékmátrix (*value matrix*). Ezeket a mátrixokat az $\mathbf{X} \in \mathbb{R}^{n \times d}$ bemeneti szekvenciális adatokat tartalmazó mátrix alapján az alábbiak szerint számolják ki:

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_q, \quad \mathbf{K} = \mathbf{X}\mathbf{W}_k, \quad \mathbf{V} = \mathbf{X}\mathbf{W}_v,$$

ahol $\mathbf{W}_q \in \mathbb{R}^{d \times d_k}$, $\mathbf{W}_k \in \mathbb{R}^{d \times d_k}$, $\mathbf{W}_v \in \mathbb{R}^{d \times d_v}$ rendre a $\mathbf{Q}, \mathbf{K}, \mathbf{V}$ mátrixokhoz tartozó tanulható súlymátrixok [26].

A Vision Transformer-t (*ViT*) Dosovitskiy et al. mutatta be 2021-ben [9]. Ez egy olyan transzformer, amely képek feldolgozására lett kifejlesztve. A ViT a bemenetként kapott képet rácsos szerkezetben részekre (*patch*) osztja; ezeket az adat-darabokat (úgynevezett *tokeneket*) alakítja aztán vektorra

és dolgozza fel. Az így előkészített tokeneket továbbítják aztán egy transzformerbe, ahol a figyelem mechanizmus már alkalmazható. A Vision Transformer szerkezetét mutatja a 5. ábra.



5. ábra. A ViT szerkezete. Az ábra Dosovitskiy et al. (2021) [9] cikkéből származik.


1.3. Kaotikus neurális hálózatok

A káosz görög eredetű szó, eredeti jelentése „tátongó úr”. Máshogy megfogalmazva a káosz egy komplex rendszer viselkedésében megnyilvánuló teljes zűrzavar vagy kiszámíthatatlanság. A káoszt a kezdeti feltételekre való rendkívüli érzékenységgel szokás azonosítani, ami a hosszútávú idősor-előrejelzést lehetetlenné teszi. Ezt először Henri Poincaré francia matematikus figyelte meg a 19. században, majd 1963-ban Edward Lorenz angol matematikus és meteorológus fogalmazta meg a káoszelméletet; tőle származik a „pillangóhatás” kifejezés is. Lorenz egy modellt készített, ami a légköri mozgásokat hivatott reprezentálni. A számításai során látszólag elhanyagolható kerekítésekkel végzett, azonban észrevette, hogy ez az előrejelzésben rendkívül nagy eltéréseket okozott. Ez a kezdeti feltételekre való érzékenység koncepciója. Az 1989-ben Benoît Mandelbrot fedezte fel a fraktálok (önhasonló objektumok; a „káosz mintázatai”) jelentőségét a kaotikus attraktorok leírásában [4, 3].

Ahhoz, hogy egy rendszer kaotikusnak nevezhessünk, az alábbi jellemzőknek kell teljesülnie:

- Nem jelenik meg periodikusság.
- Kezdeti feltételekre való érzékenység.
- Kaotikus mozgást nehéz vagy lehetetlen előrejelezni.
- Véletlenszerűnek látszó mozgás.
- Nemlineáris.

A kaotikus neurális hálózatokat (*Chaotic Neural Network, cNN*) – a káoszelmélet és neurális hálózatok ötvözetét – Aihara et al. mutatták be 1990-ben [1]. A cNN-ek a kaotikus rendszerek komplex mintázatait képesek reprezentálni és változatos megoldásokat tudnak felfedezni. A cNN neuronjai nemlineáris aktivációs függvények által kaotikus dinamikát mutatnak, amely egy ún. bifurkációs paraméter változtatásával szabályozható. Ez azért hasznos, mert így a neurális hálózat komplex – kaotikus – kapcsolatokat is felfedezhet az adatok közt. [3]. A kaotikus neuron szerkezetét a 6. ábra mutatja be.



6. ábra. A kaotikus neuron szerkezete Crook & Scheper (2001) [7] alapján. Az ábra Anusree & Pramod (2025) [3] cikkéből származik.

A bemutatott kaotikus neuron három rétegből áll. A bemeneti (*input*) réteg fogadja a bejövő dinamikus jeleket. A réteg teljesen össze van kötve (*fully connected*) a gátló (*inhibitory*) réteggel.

1.4. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják (ld. pl. Hung et al., 2009, akik ANN-t használtak az eső előrejelzésére Bangkokban [12]), azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív, több időjárási változóra is kiterjedő előrejelzést lehessen készíteni segítségével [8].

Az első jelentősebb ANN architektúrán alapuló MLWP-modell az NVIDIA 2022-ben bemutatott, Fourier neurális hálózat alapú FourCastNet (*FOURier ForeCASTing Neural NETwork*) nevű modellje. Az architektúra alapötlete a fentebb már ismertetett ViT. Azonban a ViT erőforrásigénye a pixelszámokkal négyzetesen nő, így sokdimenziós bemeneti adatoknál már nem érdemes használni. Ezen probléma áthidalására fejlesztették ki Guibas et al. 2022-ben az Adaptív Fourier Neurális Operátorokat (*Adaptive Fourier Neural Operator, AFNO*). A módszer a függvények Fourier-terén hat, ami sok számítást leegyszerűsít (pl. a kovolúcióból szorzás lesz) [10].

1.5. MLWP-modellek kaotikus tulajdonságai

Azt, hogy megállapítsuk, hogy egy modell tudja-e a kaotikus jegyeket produkálni, legegyszerűbben az előrejelzésben valamilyen kezdeti perturbáció növekedésének vizsgálatával tehetjük meg. Ha a hiba exponenciálisan nő (azaz találunk pozitív Ljapunov-exponenst), a káosz jelen van a predikcióban.

Hivatkozások

- [1] Aihara, K. et al. Chaotic neural networks. *Physics Letters A*, 144(6):333–340, March 1990. <https://www.sciencedirect.com/science/article/pii/037596019090136C>.
- [2] Alzubi, J. et al. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018. <https://doi.org/10.1088/1742-6596/1142/1/012012>.

- [3] Anusree, M. et al. Understanding chaotic neural networks: A comprehensive review. *Nonlinear Dynamics*, 113(19):25389–25404, October 2025. <https://doi.org/10.1007/s11071-025-11503-7>.
- [4] Biswas, H. R. et al. *Chaos Theory and Its Applications in Our Real Life*. 2018.
- [5] Bonavita, M. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. [_eprint: https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377](https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377), <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL107377>.
- [6] Choi, R. Y. et al. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020. <https://doi.org/10.1167/tvst.9.2.14>.
- [7] Crook, N. et al. A Novel Chaotic Neural Network Architecture. In *ESANN'2001 proceedings - European Symposium on Artificial Neural Networks*, pages 295–300, Bruges, Belgium, 2001. D-Facto public.
- [8] de Burgh-Day, C. O. et al. Machine learning for numerical weather and climate modelling: a review. *Geoscientific Model Development*, 16(22):6433–6477, November 2023. <https://gmd.copernicus.org/articles/16/6433/2023/>.
- [9] Dosovitskiy, A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale, June 2021. arXiv:2010.11929 [cs.CV], <http://arxiv.org/abs/2010.11929>.
- [10] Guibas, J. et al. Adaptive Fourier Neural Operators: Efficient Token Mixers for Transformers, March 2022. arXiv:2111.13587 [cs.CV], <http://arxiv.org/abs/2111.13587>.
- [11] Géron, A. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, Inc., Sebastopol, California, 2017.
- [12] Hung, N. Q. et al. An artificial neural network model for rainfall forecasting in Bangkok, Thailand. *Hydrology and Earth System Sciences*, 13(8):1413–1425, August 2009. <https://hess.copernicus.org/articles/13/1413/2009/hess-13-1413-2009.html>.
- [13] Kelleher, J. D. *Deep Learning*. The MIT Press, Cambridge, Massachusetts, September 2019.
- [14] Lecun, Y. et al. Convolutional networks for images, speech, and time series. 1995.
- [15] Lee, A. et al. Machine Learning Has Arrived! *Ophthalmology*, 124(12):1726–1728, December 2017. <https://linkinghub.elsevier.com/retrieve/pii/S0161642017315634>.
- [16] Medsker, L. R. et al. *Recurrent Neural Networks*. 2001.
- [17] Mitchell, T. M. *The Discipline of Machine Learning*. 2006.
- [18] Moldovan, G. et al. An update to ECMWF's machine-learned weather forecast model AIFS, September 2025. arXiv:2509.18994 [physics], <http://arxiv.org/abs/2509.18994>.
- [19] Moor, J. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27(4):87–87, December 2006. <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1911>.

- [20] Pathak, J. et al. FourCastNet: A Global Data-driven High-resolution Weather Model using Adaptive Fourier Neural Operators, February 2022. arXiv:2202.11214 [physics], <http://arxiv.org/abs/2202.11214>.
- [21] Purwono, P. et al. Understanding of Convolutional Neural Network (CNN): A Review. *International Journal of Robotics and Control Systems*, 2(4):739–748, 2022. <https://pubs2.ascee.org/index.php/IJRCS/article/view/888>.
- [22] Scarselli, F. et al. The Graph Neural Network Model. *IEEE Transactions on Neural Networks*, 20(1):61–80, 2008. <http://ieeexplore.ieee.org/document/4700287/>.
- [23] Selz, T. et al. Can Artificial Intelligence-Based Weather Prediction Models Simulate the Butterfly Effect? *Geophysical Research Letters*, 50(20):e2023GL105747, 2023. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL105747>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL105747>.
- [24] Sharifani, K. et al. Machine Learning and Deep Learning: A Review of Methods and Applications. 10(07), 2023. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723.
- [25] Sharkawy, A.-N. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020. <https://univ-brest.hal.science/hal-03114305>.
- [26] Shi, J. et al. Deep Learning and Foundation Models for Weather Prediction: A Survey, January 2025. arXiv:2501.06907 [cs.LG], <http://arxiv.org/abs/2501.06907>.
- [27] Vaswani, A. et al. Attention is All you Need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.