

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. A mesterséges intelligencia és gépi tanulás	2
1.3. Gépi tanulás alapú időjárás-előrejelző modellek	6
1.4. Káoszelméleti bevezetés	6

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszer, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [15]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; ECMWF-AIFS, 2024; illetve néhány ensemble modell: Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*Mean Squared Error, MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre. A modellfejlesztők a valósághú predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt [13].

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [3]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanul teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [16]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. A mesterséges intelligencia és gépi tanulás

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project*

on Artificial Intelligence). Felvetett elvük azon alapult, hogy „a tanulás minden aspektusa, vagy az intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet” [14, 4]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik; ezt nevezzük gépi tanulásnak [1].

Az első gépi tanulás alapú technológia az 1990-es években lett népszerű, amikor megjelentek az elektronikus levelezőrendszerekben a spamfilterek: a szűrő felhasználói bejelentésekből származó adatokon lett betanítva, megtanulva, hogy milyen jellemzői vannak egy spam e-mailnek. Az ezt követő évtizedekben egyre több gépi tanulás alapú technológia jelent meg, gondolhatunk itt a mindennapokban gyakran használt beszédfelismerő eszközökre vagy a közösségi média tartalomajánló algoritmusaira [7]. A gépi tanulást 1959-ben Arthur Samuel amerikai informatikus így definiálta [9]:

A gépi tanulás képessé teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket.

Egzaktabb definíciót nyújt Tom Mitchell szintén amerikai informatikus megfogalmazása [12]:

Egy számítógépes program valamilyen T feladat elvégzése érdekében – melynek sikerességét valamely P teljesítményt értékelő mérőszám jellemzi – E tapasztalatból tanul, ha a T elvégzése során nyújtott teljesítménye P mérőszámmal mérve az E tapasztalat megszerzésével javul.

A gépi tanulás olyan problémák megoldásában lehet rendkívül hasznos, amik túl komplexek, vagy nem ismert algoritmikus megoldásuk. Ha megnézzük, hogy a gép milyen mintázatokat ismert fel vagy kapcsolatokat tanult meg, akkor az ember is új, addig még fel nem fedezett korrelációkat vehet észre, ami által a megértésünk javulhat, ezt nevezzük adatbányászatnak (*data mining*). A példák, tapasztalatok, amik segítségével a gép tanul, a tanító adathalmaz (*training set*) részét képezik ezek a minták (*sample*) [7].


A gépi tanulásos rendszereket csoportosíthatjuk aszerint, hogy humán felügyelet alatt van-e tanítva (felügyelt – *supervised*, felügyelet nélküli – *unsupervised*, félig felügyelt – *semisupervised*, megerősítéses – *reinforcement* tanulás); menet közben tud-e fokozatosan tanulni (*online* és *batch* tanulás); illetve hogy az új adatokat a már ismertekhez hasonlíttja (példa alapú – *instance-based* tanulás) vagy a tanító adathalmazban mintázatokat ismer fel, és ez alapján előrejelzést tud adni (modell alapú – *model-based* tanulás). A legfontosabb fogalmak a fentiek közül a felügyelt, felügyelet nélküli, illetve megerősítéses tanulás [7].

A felügyelt tanulás során a tanító adathalmaz tartalmazza a kívánt kimenetet / helyes megoldást (ezt nevezzük címkének – *label*). Példa lehet erre, hogy szeretnénk betanítani egy modellt, hogy korábbi eladási adatokat ismerve jelezze előre, mennyit ér egy eladásra szánt autó. Az autónak a tulajdonságai (*feature*; mint a kora, megtett km, márka stb.) adottak. Az előrejelezni kívánt numerikus mennyiséget hívjuk *predictor*-nek vagy *target*-nek (jelen esetben ez az autó ára). Az előrejelzéshez használt algoritmus többféle lehet, legismertebb példái a lineáris regresszió és a neurális hálózat architektúrák. Felügyelet nélküli tanulás során a tanító adathalmaz nincsen felcímkézve, a modell maga tanulja meg a jellemzőket elkülöníteni. Legismertebb példa a klaszterezés (*clustering*), amikor a modell a vizsgált adatokat a megfigyelt tulajdonságaik alapján osztályozza. Megerősítéses tanulás esetén a tanuló rendszert (az ágens – *agent*) megfigyeli a környezetét és a kialakított irányelvének (*policy*) megfelelően tetteket hajt végre. A tetteiért jutalmat (*reward*) vagy büntetést (*penalty*) kap. Az ágens célja a jutalom maximalizálása, ami érdekében iteratívan frissíti az irányelvét [7].

A gépi tanulás alapú modellek problémái legtöbbször a tanító adatból származnak: gondot jelent a nem megfelelő mennyiségű, minőségű, nem elég reprezentatív, vagy irreleváns adat. Ha az adat túl zajos, felléphet a túlillesztés (*overfitting*), ami azt jelenti, hogy a modell túl komplex a feladathoz. Ha a modell túl egyszerű, azt alulillesztésnek (*underfitting*) nevezzük. Az elkészült gépi tanulás alapú

modelleket ezen hibák kiszűrése érdekében validálják, melynek népszerű eszköze az igazságmátrix (*confusion matrix*) [7].

A gépi tanulás hagyományosan statisztikai módszerek segítségével történik a megfigyelt adatok alapján. A gépi tanulás múlt században megalkotott, és az utóbbi évtizedekben elterjedt technikája egészen más megközelítést kínál; ezek a mesterséges neurális hálózatok (*Artificial Neural Network, ANN*). Az ANN-ek segítségével az adatbázisban fennálló komplex kapcsolatok is felismerhetők [17]. Az ANN-eket 1943-ban mutatta be Warren McCulloch amerikai neurofiziológus és Walter Pitts számítógépes idegtudós. Az ANN-t mesterséges neuronok alkotják, melyek működését a biológiai neuronok ihlették, melyet az 1. ábra mutat be.



1. ábra. A biológiai neuron szerkezete. Az ábra Géron *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (2017) [7] könyvéből származik.

Az általuk megalkotott ANN kijelentéslogikán alapult: a hálózatot alkotó mesterséges neuronok bemenete (*input*) egy vagy több bináris (*on/off*) adat, kimenete (*output*) egyetlen bináris adat.

A biológiai neuron (idegsejt) az agykéregben előforduló sejt, melynek főbb részei a sejttest (*cell body*), a dendritek (*dendrite*), illetve a nagyon hosszú nyúlványa, az axon. Az axon telodendronokra bomlik, melyek csúcán kis szinapszisok találhatóak, melyek a dendritekbe tudnak kapcsolódni és a neuronok kis elektromos impulzusokkal történő kommunikációjáért felelősek. Ha a neuron adott idő alatt elég jelet kap, maga is aktiválódik és jeleket ad le. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt [4]. Az agyban a neuronok egymás utáni rétegekbe vannak rendeződve, így lesz képes az emberi agy komplex feladatok elvégzésére is [7].

Az ANN rétegebe rendeződött neuronokból áll. A rétegekben csomópontok vannak, az információ feldolgozásáért felelős mesterséges neuronok pedig kapcsolatokon keresztül kommunikálnak egymással [18]. A csomópontok a biológiai neuron sejttestének feleltethetők meg, a kapcsolatok pedig hasonlóan működnek, mint az axonok és dendritek. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [4].


A gépi tanulás tehát a bemeneti és kimeneti adatok kapcsolatát leíró függvény megkeresését jelenti; ezen függvény megkeresését tanításnak (*training*) nevezzük. A függvény ismeretében a következtetési folyamat (*inference*) során új értékek jelezhetők előre. A tanításhoz felhasznált adatok általában múltbeli megfigyelésekből állnak. A megfigyelések tartalmazzák a vizsgált dolog jellemzőit (*feature*; x -el szoktuk jelölni), illetve a már ismert értékét, a címkét (*label*; y -al szoktuk jelölni). [11]. Mivel gyakran a jellemzők, illetve a címkék is vektorok, a gépi tanulás során megtanult függvény (modell) egy véges dimenziós vektorterek közötti leképezés. Az ilyen módon kapott modell kimenetét $\hat{y}$ -al szokás jelölni.

A mesterséges neuron sematikus felépítését a 2. ábra mutatja. Az x_i bemeneti értékekre (*input*) a neuron w_i súlyokat alkalmaz, melyek azt határozzák meg, hogy mennyire fontos az adott bemenet a kimenet (*output*) szempontjából. A súlyozást követő lépés az összegzés, melyet egy összegző

csomópont (*summing junction*) végez. A súlyozott bemenetek mellett egy b konstans értéket felvevő elfogultság (*bias*) is hozzáadásra kerül. Az így kapott s_j összegre ezután egy nemlineáris aktivációs függvény (*activation function*; φ -vel jelöljük) hat, amelynek eredményeként kapjuk az y_j neuron által visszaadott $\hat{y}_j$ kimeneti értéket:

$$s_j = \sum_{i=1}^m w_{ij} \cdot x_i + b_j; \quad \hat{y}_j = \varphi(s_j).$$

Az aktivációs függvény lehet pl. küszöb függvény (negatív értékekre 0-t, pozitív értékekre 1-et ad), ReLU (*REctified Linear Unit*) aktivációs függvény (a negatív értékeket lenullázza), de gyakran valamilyen szigmoid függvényt választanak erre a célra (példa erre a tangens hiperbolikus függvény: $\varphi(s) = \tanh(s)$) [18].



2. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [18] cikkéből származik (CC BY-NC 4.0).

A neurális hálózatok neuronrétegekből állnak. A neurális hálózat szerkezetét általánosan architektúrának nevezzük. Egyrétegű neurális hálózat esetén a bemenet és kimenet közt egyszeres összeköttetés van, azonban a gyakorlatban általában több neuronrétegből alkotják meg a neurális hálózatot. A több réteg (melyeket rejtett rétegeknek nevezünk – *hidden layers*) a bemeneti és kimeneti adatok közt több kapcsolatot jelent, és képes komplexebb összefüggések megtanulására is. A neuronok közti adat-továbbítás iránya szerint megkülönböztetünk előrecsatolt neurális hálózatokat (*Feedforward Neural Network*, *FNN*), illetve rekurrens neurális hálózatokat (*Recurrent Neural Network*, *RNN*). Az FNN-ekben nincsenek visszacsatolt kapcsolatok (*feedback*), ahol a modellkimenetek önmagukba visszakapcsolódhatnak. Ha a rejtett rétegek közt rekurrens kapcsolatokat is megengedünk, RNN-ről beszélünk. A rekurrens kapcsolatok egyfajta memóriát adnak a neurális hálózatnak, ezzel pedig lehetővé teszik pl. kontextus értelmezését [6].

Az utóbbi években mind jobban elterjedő modellek transzformer architektúrán alapszanak, így működik pl. a ChatGPT is. A transzformer modelleket először a Google kutatói által 2017-ben publikált „Attention Is All You Need” című cikk említette, amely azóta a mesterséges intelligencia-kutatás egyik alpművévé vált; több tízezernyi cikk hivatkozik rá [19, 2]. A transzformer modellek egyfajta encoder-decoder modellek.

inputja egy sorozatnyi token (a token a szekvenciális adat felépítő részét jelenti, például egy mondatban a szavakat, vagy egy szóban a szótagokat/betűket). A transzformer ezután reprezentációt készít minden tokenről

Az időjárás előrejelzésére sokféle architektúrát alkalmaznak, a következő fejezetben ezek közül szeretnék néhányat bemutatni.

1.3. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják (ld. pl. Hung et al., 2009, akik ANN-t használtak az eső előrejelzésére Bangkokban [cite Hung et al.]), azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív, több időjárási változóra is kiterjedő előrejelzést lehessen készíteni segítségével. Az MLWP-modellek több évtizednyi időjárási adat feldolgozása során fedezik fel a kapcsolatokat a légköri változók között, a kapcsolat ismeretében pedig már képesek előrejelzést készíteni. A kapcsolat azonban nincs szabályozva a fizikai törvények által, ami az MLWP-modellek „fekete doboz” jellegét okozza [5].

Az első jelentősebb ANN architektúrán alapuló MLWP-modell az NVIDIA 2022-ben bemutatott, Fourier neurális hálózat alapú FourCastNet (*FOURier ForeCASTing Neural NETwork*) nevű modellje. A hálózatot úgynevezett adaptív Fourier neurális operátorok (*Adaptive Fourier Neural Operator*, *AFNO*) alkotják. A neurális operátorok olyan gépi tanuláshoz használt architektúrák, melyek végtelen dimenziós függvényterek közti leképezést hajtanak végre [8]. Ha ezeket az operátorokat a függvényterek Fourier-terén hattatjuk, Fourier neurális operátorokról (*Fourier Neural Operator*, *FNO*) beszélünk [10]. Az AFNO olyan token mixer

FNO és vision transformer architektúrák (*ViT*) együttes használatával épül fel.

A Vision Transformer egy olyan architektúra, ami szekvenciális adatokban (pl. nyelvtani mondatok) képes komplex kapcsolatokat felfedezni.

1.4. Káoszelméleti bevezetés

A káosz ősi görög eredetű szó, ami eredetileg a szisztematikus elrendezés teljes hiányát jelentette. Ma valamilyen rend hiányának kifejezésére használják, aminek jelen kellene lennie.

Hivatkozások

- [1] Alzubi, J. et al. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018. <https://doi.org/10.1088/1742-6596/1142/1/012012>.
- [2] Amatriain, X. et al. Transformer models: an introduction and catalog, March 2024. arXiv:2302.07730 [cs.CL], <http://arxiv.org/abs/2302.07730>.
- [3] Bonavita, M. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL107377>.
- [4] Choi, R. Y. et al. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020. <https://doi.org/10.1167/tvst.9.2.14>.
- [5] de Burgh-Day, C. O. et al. Machine learning for numerical weather and climate modelling: a review. *Geoscientific Model Development*, 16(22):6433–6477, November 2023. <https://gmd.copernicus.org/articles/16/6433/2023/>.
- [6] Goodfellow, I. et al. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [7] Géron, A. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, Inc., Sebastopol, California, 2017.

- [8] Kovachki, N. et al. Neural Operator: Learning Maps Between Function Spaces, May 2024. arXiv:2108.08481 [cs.LG], <http://arxiv.org/abs/2108.08481>.
- [9] Lee, A. et al. Machine Learning Has Arrived! *Ophthalmology*, 124(12):1726–1728, December 2017. <https://linkinghub.elsevier.com/retrieve/pii/S0161642017315634>.
- [10] Li, Z. et al. Fourier Neural Operator for Parametric Partial Differential Equations, May 2021. arXiv:2010.08895 [cs.LG], <http://arxiv.org/abs/2010.08895>.
- [11] Microsoft. Introduction to Machine Learning Concepts - Training, 2026. <https://learn.microsoft.com/en-us/training/modules/fundamentals-machine-learning/>.
- [12] Mitchell, T. M. The Discipline of Machine Learning. 2006.
- [13] Moldovan, G. et al. An update to ECMWF’s machine-learned weather forecast model AIFS, September 2025. arXiv:2509.18994 [physics], <http://arxiv.org/abs/2509.18994>.
- [14] Moor, J. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27(4):87–87, December 2006. <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1911>.
- [15] Pathak, J. et al. FourCastNet: A Global Data-driven High-resolution Weather Model using Adaptive Fourier Neural Operators, February 2022. arXiv:2202.11214 [physics], <http://arxiv.org/abs/2202.11214>.
- [16] Selz, T. et al. Can Artificial Intelligence-Based Weather Prediction Models Simulate the Butterfly Effect? *Geophysical Research Letters*, 50(20):e2023GL105747, 2023. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL105747>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL105747>.
- [17] Sharifani, K. et al. Machine Learning and Deep Learning: A Review of Methods and Applications. 10(07), 2023. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723.
- [18] Sharkawy, A.-N. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020. <https://univ-brest.hal.science/hal-03114305>.
- [19] Vaswani, A. et al. Attention is All you Need. In *Advances in Neural Information Processing Systems*, volume 30. Curran Associates, Inc., 2017. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.