


Eötvös Loránd Tudományegyetem Természettudományi Kar

A gépi tanuláson alapuló időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálata

Szakdolgozat
Fizika alapszak
Meteorológus specializáció



ELTE
EÖTVÖS LORÁND
TUDOMÁNYEGYETEM

Készítette: **Opposits Ágota**

Témavezetők:
Leelőssy Ádám
ELTE Meteorológiai Tanszék
Haszpra Tímea
ELTE Elméleti Fizikai Tanszék

Budapest, 2027

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró bonyolult, nemlineáris egyenletrendszert, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – ún. reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, az European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [*cite fourcastnet*]. A 2022 óta eltelt években sorra jelentek meg a determinisztikus és ensemble MLWP-modellek (pl. Huawei PanguWeather, 2023; Google GraphCast, 2023; ECMWF-AIFS, 2024; Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen, hogy a modellek – gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba, *MSE* alapú – költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés adása is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre [*cite*]. A modellfejlesztők a valósághű predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt.

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [*cite Bonavita*]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban így azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanra teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [*cite, valahol olvastam ezt így*]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.