


Eötvös Loránd Tudományegyetem Természettudományi Kar

A gépi tanuláson alapuló időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálata

Szakdolgozat
Fizika alapszak
Meteorológus specializáció



ELTE
EÖTVÖS LORÁND
TUDOMÁNYEGYETEM

Készítette: **Opposits Ágota**

Témavezetők:
Leelőssy Ádám
ELTE Meteorológiai Tanszék
Haszpra Tímea
ELTE Elméleti Fizikai Tanszék

Budapest, 2027

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. Gépi tanulás alapfogalmai	2
1.3. Gépi tanulás alapú időjárás-előrejelző modellek	3
1.4. Káoszelméleti bevezetés	3

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszer, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [*cite fourcastnet*]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; illetve néhány ensemble modell: ECMWF-AIFS, 2024; Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre [*cite*]. A modellfejlesztők a valósághű predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt.

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [*cite Bonavita*]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban így azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanra teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [*cite, valahol olvastam ezt így*]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. Gépi tanulás alapfogalmai

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project on Artificial Intelligence*). Felvetett elvük azon alapult, hogy ”a tanulás minden aspektusa, vagy az

intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet”. A mesterséges intelligencia tehát a gondolkodás automatizálását jelenti, a gépi tanulás pedig egy módszer ennek elérésére [cite Moor, Choi et al.].

A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik [cite Alzubi]. Arthur Samuel amerikai informatikus megfogalmazása szerint a gépi tanulás ”képesse teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket” [cite Aaron Lee].

A gépi tanulás megvalósítása korábban statisztikai módszerekkel, mint a lineáris regresszió történt. Az elmúlt évtizedekben kezdték el gépi tanítás céljából alkalmazni a mesterséges neurális hálózatokat (*Artificial Neural Network, ANN*), melyek az emberi agy működését imitálják. A hálózat csomópontokból áll, a neuronok pedig kapcsolatokon keresztül kommunikálnak egymással. A csomópontok a biológiai neuron sejttestének feleltethetők meg, a kapcsolatok pedig hasonlóan működnek, mint az idegsejtek kapcsolódásáért felelős axonok és dendritek. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg. A tanulás folyamata során a cél, hogy a neurális háló kimenetele minél jobban megközelítse a kívánt kimenetelt; ennek érdekében a súlyok erőssége kerül változtatásra [cite Choi].

1.3. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják, azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív előrejelzést lehessen készíteni segítségével. Az MLWP-modellek több évtizednyi időjárási adat feldolgozása során fedezik fel a kapcsolatokat a légköri változók között, a kapcsolat ismeretében pedig már képesek előrejelzést is készíteni. A kapcsolat azonban nincs szabályozva a fizikai törvények által, ami az MLWP-modellek „fekete doboz” jellegét okozza. Ha viszont nem csak az ismert fizikai törvények érvényesülnek az előrejelzés készítése során, a hibás előrejelzések okának feltárása és a javítás rendkívül nehézé válik [cite de Burgh-Day].

A következőkben néhány MLWP-modell működésén keresztül szeretném felvázolni, hogy miképpen lehet alkalmazni a gépi tanulós architektúrákat az időjárás előrejelzésére.

A 2023-ban nyilvánosságra hozott NVIDIA FourCastNet (*FOURier ForeCASTing Neural NETWORK*) modell Fourier neurális hálózat alapú. Ez a fajta neurális hálózat Fourier Neural Operator-ok (*FNO*) és Vision Transformer-ek (*ViT*) együttes használatával létrejött Adaptive Fourier Neural Operator-ok (*AFNO*) segítségével épül fel.

1.4. Káoszelméleti bevezetés

A légkör egy kaotikus fizikai rendszer, ami azt jelenti, hogy a kis kezdeti hiba idővel exponenciálisan növekszik, azaz a kezdőfeltételekre rendkívül érzékeny. A kezdeti állapotot azonban nem ismerjük egészen pontosan, mivel nem léteznek tökéletes mérések.

A káosz kizárólag időben rendezetlen viselkedést jelent [cite Tél Turbulencia vagy káosz?].