


Eötvös Loránd Tudományegyetem Természettudományi Kar

A gépi tanuláson alapuló időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálata

Szakdolgozat
Fizika alapszak
Meteorológus specializáció



ELTE
EÖTVÖS LORÁND
TUDOMÁNYEGYETEM

Készítette: **Opposits Ágota**

Témavezetők:
Leelőssy Ádám
ELTE Meteorológiai Tanszék
Haszpra Tímea
ELTE Elméleti Fizikai Tanszék

Budapest, 2027

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. Mesterséges neurális hálózatok alapfogalmai	2
1.3. Gépi tanulás alapú időjárás-előrejelző modellek	4

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszer, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [10]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; illetve néhány ensemble modell: ECMWF-AIFS, 2024; Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*Mean Squared Error, MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre [8]. A modellfejlesztők a valósághú predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt.

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [2]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban így azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanul teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [11]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. Mesterséges neurális hálózatok alapfogalmai

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project*


on Artificial Intelligence). Felvetett elvük azon alapult, hogy „a tanulás minden aspektusa, vagy az intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet”. A mesterséges intelligencia tehát a gondolkodás automatizálását jelenti, a gépi tanulás pedig egy módszer ennek elérésére [9, 3]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik [1]. A gépi tanulás tehát a bemeneti és kimeneti adatok kapcsolatát leíró függvény megkeresését jelenti; ezen függvény megkeresését tanításnak (*training*) nevezzük. A függvény ismeretében a következtetési folyamat (*inference*) során új értékek jelezhetőek előre. A tanításhoz felhasznált adatok általában múltbeli megfigyelésekből állnak. A megfigyelések tartalmazzák a vizsgált dolog jellemzőit (*feature*; x -el szoktuk jelölni), illetve a már ismert értékét, a címkét (*label*; y -al szoktuk jelölni). [7]. Mivel gyakran a jellemzők, illetve a címkék is vektorok, a gépi tanulás során megtanult függvény (modell) egy véges dimenziós vektorterek közötti leképezés. Az ilyen módon kapott modell kimenetét $\hat{y}$ -al szokás jelölni.

A gépi tanulás hagyományosan statisztikai módszerek segítségével tanul a megfigyelt adatokból. Ezzel szemben az elmúlt években egyre gyakrabban használt mélytanulás (*Deep Learning, DL*) mesterséges neurális hálózatok (*Artificial Neural Network, ANN*) segítségével képes megtanulni az adatbázisban fennálló komplex kapcsolatokot [12]. Az ANN-ek az emberi agy működését imitálják. A hálózat csomópontokból áll, az információ feldolgozásáért felelős neuronok pedig kapcsolatokon keresztül kommunikálnak egymással [13]. A csomópontok a biológiai neuron sejttestének feleltethetőek meg, a kapcsolatok pedig hasonlóan működnek, mint az idegsejtek kapcsolódásáért felelős axonok és dendritok. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [3].

A mesterséges neuron sematikus felépítését a 1. ábra mutatja. Az x_i bemeneti értékekre (*input*) a neuron w_i súlyokat alkalmaz, melyek azt határozzák meg, hogy mennyire fontos az adott bemenet a kimenet (*output*) szempontjából. A súlyozást követő lépés az összegzés, melyet egy összegző csomópont (*summing junction*) végez. A súlyozott bemenetek mellett egy b konstans értéket felvevő elfogultság (*bias*) is hozzáadásra kerül. Az így kapott s_j összegre ezután egy nemlineáris aktivációs függvény (*activation function*; φ -vel jelöljük) hat, amelynek eredményeként kapjuk az y_j neuron által visszaadott $\hat{y}_j$ kimeneti értéket:

$$s_j = \sum_{i=1}^m w_{ij} \cdot x_i + b_j; \quad \hat{y}_j = \varphi(s_j).$$

Az aktivációs függvény lehet pl. küszöb függvény (negatív értékekre 0-t, pozitív értékekre 1-et ad), ReLU (*REctified Linear Unit*) aktivációs függvény (a negatív értékeket lenullázza), de gyakran valamilyen szigmoid függvényt választanak erre a célra (példa erre a tangens hiperbolikus függvény: $\varphi(s) = \tanh(s)$) [13].



1. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [13] cikkéből származik (CC BY-NC 4.0).

A neurális hálózatok neuronrétegekből állnak. A neurális hálózat szerkezetét általánosan architektúrának nevezzük. Egyrétegű neurális hálózat esetén a bemenet és kimenet közt egyszeres összeköttetés van, azonban a gyakorlatban általában több neuronrétegből alkotják meg a neurális hálózatot. A több réteg (melyeket rejtett rétegeknek nevezünk – *hidden layers*) a bemeneti és kimeneti adatok közt több kapcsolatot jelent, és képes komplexebb összefüggések megtanulására is. A neuronok közti adat-továbbítás iránya szerint megkülönböztetünk előrecsatolt neurális hálózatokat (*Feedforward Neural Network, FNN*), illetve rekurrens neurális hálózatokat (*Recurrent Neural Network, RNN*). Az FNN-ekben nincsenek visszacsatolt kapcsolatok (*feedback*), ahol a modellkimenetek önmagukba visszakapcsolódhatnak. Ha a rejtett rétegek közt rekurrens kapcsolatokat is megengedünk, RNN-ről beszélünk. A rekurrens kapcsolatok egyfajta memóriát adnak a neurális hálózatnak, ezzel pedig lehetővé teszik pl. kontextus értelmezését [5].

Az időjárás előrejelzésére sokféle architektúrát alkalmaznak, a következő fejezetben ezek közül szeretnék néhányat bemutatni.

1.3. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják (ld. pl. Hung et al., 2009, akik ANN-t használtak az eső előrejelzésére Bangkokban [*cite Hung et al.*]), azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív, több időjárási változóra is kiterjedő előrejelzést lehessen készíteni segítségével. Az MLWP-modellek több évtizednyi időjárási adat feldolgozása során fedezik fel a kapcsolatokat a légköri változók között, a kapcsolat ismeretében pedig már képesek előrejelzést készíteni. A kapcsolat azonban nincs szabályozva a fizikai törvények által, ami az MLWP-modellek „fekete doboz” jellegét okozza [4].

Az első jelentősebb ANN architektúrán alapuló MLWP-modell az NVIDIA 2022-ben bemutatott, Fourier neurális hálózat alapú FourCastNet (*FOURier ForeCASTing Neural NETwork*) nevű modellje. A hálózatot úgynevezett adaptív Fourier neurális operátorok (*Adaptive Fourier Neural Operator, AFNO*) alkotják. A neurális operátorok olyan gépi tanulóhoz használt architektúrák, melyek – ellenben a végtelen dimenziós függvényterek közti leképezésekkel – végtelen dimenziós függvényterek közti leképezést hajtanak végre [6]. Ha ezeket az operátorokat a függvényterek Fourier-terén hattatjuk, Fourier neurális operátorokról (*Fourier Neural Operator, FNO*) beszélünk [10]. Az AFNO FNO és Vision Transformer architektúrák (*ViT*) együttes használatával épül fel. A Vision Transformer egy olyan architektúra, ami szekvenciális adatokban (pl. nyelvtani mondatok) képes komplex kapcsolatokat felfedezni.

Hivatkozások

- [1] Alzubi, J. et al. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018. <https://doi.org/10.1088/1742-6596/1142/1/012012>.
- [2] Bonavita, M. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL107377>.
- [3] Choi, R. Y. et al. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020. <https://doi.org/10.1167/tvst.9.2.14>.
- [4] de Burgh-Day, C. O. et al. Machine learning for numerical weather and climate modelling: a review. *Geoscientific Model Development*, 16(22):6433–6477, November 2023. <https://gmd.copernicus.org/articles/16/6433/2023/>.
- [5] Goodfellow, I. et al. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [6] Kovachki, N. et al. Neural Operator: Learning Maps Between Function Spaces, May 2024. arXiv:2108.08481 [cs.LG], <http://arxiv.org/abs/2108.08481>.
- [7] Microsoft. Introduction to Machine Learning Concepts - Training, 2026. <https://learn.microsoft.com/en-us/training/modules/fundamentals-machine-learning/>.
- [8] Moldovan, G. et al. An update to ECMWF’s machine-learned weather forecast model AIFS, September 2025. arXiv:2509.18994 [physics], <http://arxiv.org/abs/2509.18994>.
- [9] Moor, J. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27(4):87–87, December 2006. <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1911>.
- [10] Pathak, J. et al. FourCastNet: A Global Data-driven High-resolution Weather Model using Adaptive Fourier Neural Operators, February 2022. arXiv:2202.11214 [physics], <http://arxiv.org/abs/2202.11214>.
- [11] Selz, T. et al. Can Artificial Intelligence-Based Weather Prediction Models Simulate the Butterfly Effect? *Geophysical Research Letters*, 50(20):e2023GL105747, 2023. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL105747>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL105747>.
- [12] Sharifani, K. et al. Machine Learning and Deep Learning: A Review of Methods and Applications. 10(07), 2023. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723.
- [13] Sharkawy, A.-N. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020. <https://univ-brest.hal.science/hal-03114305>.