

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. A mesterséges intelligencia és gépi tanulás	2

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszer, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [10]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; ECMWF-AIFS, 2024; illetve néhány ensemble modell: Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*Mean Squared Error, MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre. A modellfejlesztők a valósághű predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt [8].

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [2]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlanul teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [11]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.

1.2. A mesterséges intelligencia és gépi tanulás

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project on*

Artificial Intelligence). Felvetett elvük azon alapult, hogy „a tanulás minden aspektusa, vagy az intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet” [9, 3]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik; ezt nevezzük gépi tanulásnak [1].

Az első gépi tanulás alapú technológia az 1990-es években lett népszerű, amikor megjelentek az elektronikus levelezőrendszerekben a spamfilterek: a szűrő felhasználói bejelentésekből származó adatokon lett betanítva, megtanulva, hogy milyen jellemzői vannak egy spam e-mailnek. Az ezt követő évtizedekben egyre több gépi tanulás alapú technológia jelent meg, gondolhatunk itt a mindennapokban gyakran használt beszédfelismerő eszközökre vagy a közösségi média tartalomajánló algoritmusaira [4]. A gépi tanulást 1959-ben Arthur Samuel amerikai informatikus így definiálta [6]:

A gépi tanulás képessé teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket.

Egzaktabb definíciót nyújt Tom Mitchell szintén amerikai informatikus megfogalmazása [7]:

Egy számítógépes program valamilyen T feladat elvégzése érdekében – melynek sikerességét valamely P teljesítményt értékelő mérőszám jellemzi – E tapasztalatból tanul, ha a T elvégzése során nyújtott teljesítménye P mérőszámmal mérve az E tapasztalat megszerzésével javul.

A gépi tanulás olyan problémák megoldásában lehet rendkívül hasznos, amik túl komplexek, vagy nem ismert algoritmikus megoldásuk. Ha megnézzük, hogy a gép milyen mintázatokat ismert fel vagy kapcsolatokat tanult meg, akkor az ember is új, addig még fel nem fedezett korrelációkat vehet észre, ami által a megértésünk javulhat, ezt nevezzük adatbányászatnak (*data mining*). A példák, tapasztalatok, amik segítségével a gép tanul, a tanító adathalmaz (*training set*) részét képezik ezek a minták (*sample*) [4].


A gépi tanulós rendszereket csoportosíthatjuk aszerint, hogy humán felügyelet alatt van-e tanítva (felügyelt – *supervised*, felügyelet nélküli – *unsupervised*, félig felügyelt – *semisupervised*, megerősítéses – *reinforcement* tanulás); menet közben tud-e fokozatosan tanulni (*online* és *batch* tanulás); illetve hogy az új adatokat a már ismertekhez hasonlítsa (példa alapú – *instance-based* tanulás) vagy a tanító adathalmazban mintázatokat ismer fel, és ez alapján előrejelzést tud adni (modell alapú – *model-based* tanulás). A legfontosabb fogalmak a fentiek közül a felügyelt, felügyelet nélküli, illetve megerősítéses tanulás [4].

A felügyelt tanulás során a tanító adathalmaz tartalmazza a kívánt kimenetet / helyes megoldást (ezt nevezzük címkének – *label*). Példa lehet erre, hogy szeretnénk betanítani egy modellt, hogy korábbi eladási adatokat ismerve jelezze előre, mennyit ér egy eladásra szánt autó. Az autónak a tulajdonságai (*feature*; mint a kora, megtett km, márka stb.) adottak. Az előrejelezni kívánt numerikus mennyiséget hívjuk *predictor*-nek vagy *target*-nek (jelen esetben ez az autó ára). Az előrejelzéshez használt algoritmus többféle lehet, legismertebb példái a lineáris regresszió és a neurális hálózat architektúrák. Felügyelet nélküli tanulás során a tanító adathalmaz nincsen felcímkézve, a modell maga tanulja meg a jellemzőket elkülöníteni. Legismertebb példa a klaszterezés (*clustering*), amikor a modell a vizsgált adatokat a megfigyelt tulajdonságaik alapján osztályozza. Megerősítéses tanulás esetén a tanuló rendszert (az ágens – *agent*) megfigyeli a környezetét és a kialakított irányelvének (*policy*) megfelelően tetteket hajt végre. A tetteiért jutalmat (*reward*) vagy büntetést (*penalty*) kap. Az ágens célja a jutalom maximalizálása, ami érdekében iteratívan frissíti az irányelvét [4].

A gépi tanulás alapú modellek problémái legtöbbször a tanító adatból származnak: gondot jelent a nem megfelelő mennyiségű, minőségű, nem elég reprezentatív, vagy irreleváns adat. Ha az adat túl zajos, felléphet a túlillesztés (*overfitting*), ami azt jelenti, hogy a modell túl komplex a feladathoz. Ha a modell túl egyszerű, azt alulillesztésnek (*underfitting*) nevezzük. Az elkészült gépi tanulás alapú

modelleket ezen hibák kiszűrése érdekében validálják, melynek népszerű eszköze az igazságmátrix (*confusion matrix*) [4].

A gépi tanulás hagyományosan statisztikai módszerek segítségével történik a megfigyelt adatok alapján. A gépi tanulás múlt században megalkotott, és az utóbbi évtizedekben elterjedt technikája egészen más megközelítést kínál; ezek a mesterséges neurális hálózatok (*Artificial Neural Network, ANN*). Az ANN-ek segítségével az adatbázisban fennálló komplex kapcsolatok is felismerhetők [12]. Az ANN-eket 1943-ban mutatta be Warren McCulloch amerikai neurofiziológus és Walter Pitts számítógépes idegtudós. Az ANN-t mesterséges neuronok alkotják, melyek működését a biológiai neuronok ihlették, melyet az 1. ábra mutat be.



1. ábra. A biológiai neuron szerkezete. Az ábra Géron *Hands-On Machine Learning with Scikit-Learn and TensorFlow* (2017) [4] könyvéből származik.

A biológiai neuron (idegsejt) az agykéregben előforduló sejt, melynek főbb részei a sejttest (*cell body*), a dendritek (*dendrite*), illetve a nagyon hosszú nyúlványa, az axon. Az axon telodendronokra bomlik, melyek csúcsán kis szinapszisok találhatók, melyek a dendritekbe tudnak kapcsolódni és a neuronok kis elektromos impulzusokkal történő kommunikációjáért felelősek. Ha a neuron adott idő alatt elég jelet kap, maga is aktiválódik és jeleket ad le. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt [3]. Az agyban a neuronok egymás utáni rétegekbe vannak rendeződve, így lesz képes az emberi agy komplex feladatok elvégzésére is [4].

Az ANN rétegebe rendeződött neuronokból áll. A rétegekben csomópontok vannak, az információ feldolgozásáért felelős mesterséges neuronok pedig kapcsolatokon keresztül kommunikálnak egymással [13]. A csomópontok a biológiai neuron sejttestének feleltethetők meg, a kapcsolatok pedig hasonlóan működnek, mint az axonok és dendritek. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [3].


A McCulloch és Pitts által megalkotott ANN kijelentéslogikán alapult. A neuronok egy vagy több bináris (*on/off* típusú) bemenetet (*input*) fogadtak, és egyetlen kimenetet (*output*) adtak. A biológiai neuronok aktiválódását úgy imitálták, hogy a mesterséges neuron csak akkor adott kimenetet, ha a kapott bemenetek száma elért egy bizonyos értéket.

Az egyik legegyszerűbb neurális hálózat a Perceptron, melyet 1957-ben Frank Rosenblatt mutatott be. Úgynevezett küszöb logikai egységek (*Threshold Logic Unit, TLU*) a mesterséges neuronok, az input és output értékek pedig numerikusak; minden input – fontosságának megfelelően – súlyozva van. A súlyozott bemenetek mellett egy b konstans értéket felvevő elfogultság (*bias*) is hozzáadásra szokott kerülni. A TLU egy súlyozott összeget számol, majd egy nemlineáris aktivációs függvényt hatar az eredményre, és ezt adja outputnak. Az aktivációs függvényre azért van szükség, hogy a lineárisnál bonyolultabb kapcsolatokat is képes legyen megtanulni az ANN. Aktivációs függvény lehet pl. a Heaviside-féle egységfüggvény, ReLu (*REctified LINEar Unit*, ami a negatív értékeket lenullázza), de gyakran valamilyen szigmoid függvényt alkalmaznak a célra, mint a tangens hiperbolikus vagy a

logisztikus függvény. A mesterséges neuron működését az alábbi egyenlet foglalja össze:

$$s_j = \sum_{i=1}^m w_{ij} \cdot x_i + b_j; \quad \hat{y}_j = \varphi(s_j),$$

ahol x_i az input, b_j a bias, w_{ij} a súlymátrix, s_j a súlyozott összeg, φ az aktivációs függvény, $\hat{y}_j$ pedig az output. A fentebb leírt mesterséges neuron működését mutatja be a 2. ábra. [13, 4, 5].



2. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [13] cikkéből származik (CC BY-NC 4.0).

Egyszeres neuronréteg azonban csak egyszerűbb feladatok elvégzésére alkalmazható; ha bonyolultabb problémákat szeretnénk megoldani, több rétegre van szükség. A kettőnél több rétegből álló ANN-t mély neurális hálózatként (*Deep Neural Network, DNN*) nevezzük. Ennek legegyszerűbb példája a többrétegű Perceptron (*Multilayer Perceptron, MLP*), ami több rétegnyi TLU-ból áll, melyeket rejtett rétegeknek (*hidden layers*) nevezünk. Minden réteg teljesen hozzá van kapcsolva a szomszédos réteghez (*Fully Connected, FL*) [4].

A bonyolultabb feladatok elvégzésére tehát mélytanulások (*Deep Learning, DL*) technológiák alkalmasak. Mélytanulások architektúrái többek között a konvolúciós neurális hálózat (*Convolutional Neural Network, CNN*), rekurrens neurális hálózat (*Recurrent Neural Network, RNN*), a transzformer architektúra (*Transformer*), vagy a gráfolapú neurális hálózat (*Graph Neural Network, GNN*).

Hivatkozások

- [1] Alzubi, J. et al. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018. <https://doi.org/10.1088/1742-6596/1142/1/012012>.
- [2] Bonavita, M. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. [_eprint: https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377](https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377), <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL107377>.
- [3] Choi, R. Y. et al. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020. <https://doi.org/10.1167/tvst.9.2.14>.

- [4] Géron, A. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, Inc., Sebastopol, California, 2017.
- [5] Kelleher, J. D. *Deep Learning*. The MIT Press, Cambridge, Massachusetts, September 2019.
- [6] Lee, A. et al. Machine Learning Has Arrived! *Ophthalmology*, 124(12):1726–1728, December 2017. <https://linkinghub.elsevier.com/retrieve/pii/S0161642017315634>.
- [7] Mitchell, T. M. *The Discipline of Machine Learning*. 2006.
- [8] Moldovan, G. et al. An update to ECMWF's machine-learned weather forecast model AIFS, September 2025. arXiv:2509.18994 [physics], <http://arxiv.org/abs/2509.18994>.
- [9] Moor, J. The Dartmouth College Artificial Intelligence Conference: The Next Fifty Years. *AI Magazine*, 27(4):87–87, December 2006. <https://ojs.aaai.org/aimagazine/index.php/aimagazine/article/view/1911>.
- [10] Pathak, J. et al. FourCastNet: A Global Data-driven High-resolution Weather Model using Adaptive Fourier Neural Operators, February 2022. arXiv:2202.11214 [physics], <http://arxiv.org/abs/2202.11214>.
- [11] Selz, T. et al. Can Artificial Intelligence-Based Weather Prediction Models Simulate the Butterfly Effect? *Geophysical Research Letters*, 50(20):e2023GL105747, 2023. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL105747>, <https://onlinelibrary.wiley.com/doi/abs/10.1029/2023GL105747>.
- [12] Sharifani, K. et al. Machine Learning and Deep Learning: A Review of Methods and Applications. 10(07), 2023. https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723.
- [13] Sharkawy, A.-N. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020. <https://univ-brest.hal.science/hal-03114305>.