


Eötvös Loránd Tudományegyetem Természettudományi Kar

A gépi tanuláson alapuló időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálata

Szakdolgozat
Fizika alapszak
Meteorológus specializáció



ELTE
EÖTVÖS LORÁND
TUDOMÁNYEGYETEM

Készítette: **Opposits Ágota**

Témavezetők:
Leelőssy Ádám
ELTE Meteorológiai Tanszék
Haszpra Tímea
ELTE Elméleti Fizikai Tanszék

Budapest, 2027

Tartalomjegyzék

1. Bevezetés	2
1.1. Célkitűzés	2
1.2. Gépi tanulás alapfogalmai	2
1.3. Gépi tanulás alapú időjárás-előrejelző modellek	4
1.4. Káoszelméleti bevezetés	4

1. Bevezetés

1.1. Célkitűzés

A huszadik század eleje óta – többek között a „bergeni iskola” neves kutatóinak köszönhetően – ismerjük a légkör működését leíró nemlineáris egyenletrendszert, az úgynevezett kormányzó egyenleteket. Az időjárás-előrejelzés hagyományosan ezen egyenletrendszer integrálásán alapul, melyet szuperszámítógépeken futó numerikus modellek hajtanak végre (*Numerical Weather Prediction, NWP*). Az utóbbi években jelentős áttörés történt az időjárás-előrejelzés területén: a 2020-as évek elején megjelentek a gépi tanulás alapuló időjárás-előrejelző modellek (*Machine Learning-based Weather Prediction, MLWP*). A gépi tanulás alapú modellek rekonstruált historikus időjárási adatokból – úgynevezett reanalízis adatokból –, illetve operatív NWP-előrejelzésekből tanulják meg a légköri folyamatok mintázatait, és ezáltal képesek a kiinduló adatok – a peremfeltételek – ismeretében predikciót adni a jövő várható időjárására. Az eltérő megközelítés folytán több előny és hátrány is megjelenik a hagyományos NWP-modellekhez képest.

Az MLWP-modellek legnagyobb előnye, hogy rendkívül rövid idő alatt képesek előrejelzést készíteni, melyek pontossága összevethető a hagyományos modellekével. Az első ilyen jelentősebb modell, az NVIDIA FourCastNet 2022-es publikációjában szereplő adatok is ezt támasztják alá: a modell 2 másodperc alatt képes egyhetes időjárás-előrejelzést készíteni, pontossága pedig az egyik legjobb NWP-modell, a European Centre for Medium-Range Weather Forecasting (*ECMWF*) IFS nevű modelljével összemérhető [*cite fourcastnet*]. A 2022 óta eltelt években sorra jelentek meg az MLWP-modellek (pl. Huawei Pangu-Weather, 2023; Google GraphCast, 2023; FuXi, 2023; FengWu, 2023; illetve néhány ensemble modell: ECMWF-AIFS, 2024; Google GenCast, 2024; ECMWF AIFS ENS, 2025), és a tapasztalatok egybehangzóak: az előrejelzések rendkívül gyorsak és pontosak, ami megfelelő indok arra, hogy a modelleket még tovább fejlesszék.

A további fejlesztés mellett szól az adatalapú megközelítésből adódó alapvető hátulütők kiküszöbölésére való törekvés is. Egyik ilyen abból ered, hogy a modellek gyakran valamilyen négyzetes hiba, mint a négyzetes középhiba (*MSE*) alapú költségfüggvény minimalizálására vannak betanítva. Ennek következtében igyekeznek elkerülni a szélsőséges értékek predikcióját, mivel tévesen megállapított kiugró érték jelentős büntetést eredményezne. Az ilyen módon előálló szélsőérték-kerülést nevezzük „smoothing”-nak, utalva arra, hogy a kiugró csúcsok mintegy elmosásra kerülnek.

Másrészt – mivel a modell nem ismeri a légköri kormányzó egyenleteket, hanem csak korábbi időjárási adatok mintázataiból tanul – elvileg lehetséges a fizikai valósággal inkonzisztens előrejelzés készítése is. Ilyen volt pl. az ECMWF-AIFS egy korábbi verziójának az a hibája, hogy negatív csapadékmennyiséget jelzett előre [*cite*]. A modellfejlesztők a valósághű predikciókat elérendő fizikai kényszerfeltételek bevezetésével korlátozzák a modellt.

Többek között a fentebb említett hibák miatt a szakirodalom jelenleg nem tekinti az MLWP modelleket a légkör megfelelő szimulátorainak [2]. A szakirodalomban azonban még nem sok kutatás tűzte ki céljául a gépi tanulás alapú időjárás-előrejelző modellek kaotikus tulajdonságainak vizsgálatát. Kutatásomban így azt szeretném megvizsgálni, hogy a fizikai törvények helyett adatokon alapuló megközelítés kimutathatatlaná teszi-e az előrejelzésekben a légkör egy alapvető tulajdonságát, a káoszt. Amennyiben a modellek nem tudják reprodukálni a kaotikus jegyeket, úgy hamis biztosságot adhatnak a hosszú távú előrejelzések megbízhatóságára [*cite, valahol olvastam ezt így*]. Ha azonban észlelhető a káosz a modell előrejelzéseiben, az azt jelenti, hogy az adatalapú tanítás következtében mégsem vész el minden fizikai törvényszerűség.


1.2. Gépi tanulás alapfogalmai

A mesterséges intelligencia fogalmát John McCarthy, Marvin Minsky, Claude Shannon és Nathaniel Rochester alkották meg 1956-ban a Dartmouth workshop-on (*Dartmouth Summer Research Project on Artificial Intelligence*). Felvetett elvük azon alapult, hogy ”a tanulás minden aspektusa, vagy az

intelligencia bármely más jellemzője elvileg olyan pontosan leírható, hogy egy géppel azt szimulálni lehet”. A mesterséges intelligencia tehát a gondolkodás automatizálását jelenti, a gépi tanulás pedig egy módszer ennek elérésére [cite Moor, Choi et al.]. A tanulás általános fogalma új ismeretek, képességek és viselkedésminták elsajátítását vagy módosítását jelenti. A mintázatok megismerése által lehetővé válik a jövőre vonatkozó előrejelzések készítése. Gépek esetében a tanuláshoz szükséges tapasztalatszerzés adatok alapján, mintázatfelismerés által történik [1]. Arthur Samuel amerikai informatikus megfogalmazása szerint a gépi tanulás ”képessé teszi a számítógépeket a tanulásra anélkül, hogy explicit módon programoznánk őket” [5].

A gépi tanulás megvalósítása korábban statisztikai módszerekkel, mint a lineáris regresszió történt. Az elmúlt évtizedekben kezdtek el gépi tanítás céljából alkalmazni a mesterséges neurális hálózatokat (*Artificial Neural Network, ANN*), melyek az emberi agy működését imitálják. A hálózat csomópontokból áll, az információ feldolgozásáért felelős [6] neuronok pedig kapcsolatokon keresztül kommunikálnak egymással. A csomópontok a biológiai neuron sejttestének feleltethetőek meg, a kapcsolatok pedig hasonlóan működnek, mint az idegsejtek kapcsolódásáért felelős axonok és dendrittek. A biológiai neuronok közti kapcsolódási pont a szinapszis, ami erősödik, ha a két neuron gyakran aktiválódik együtt. A mesterséges neuronok közti kapcsolat erősségét a súlyok (*weight*) határozzák meg [3].

A mesterséges neuron sematikus felépítését a 1. ábra mutatja. Az $x_1, x_2, \dots, x_m$ bemeneti értékekre (*inputok*) a neuron súlyokat haddat, melyek azt határozzák meg, hogy mennyire fontos az adott bemenet a kimenet szempontjából. A súlyozást követő lépés az összegzés, melyet egy összegző csomópont (*Summing Junction*) végez. A súlyozott bemenetek mellett egy x_0 konstans értéket felvevő elfogultságot (*bias*) is hozzáadásra kerül. Az így kapott s_j összegre ezután egy nemlineáris aktivációs függvény (*Activation Function*; φ) hat, amelynek eredményeként kapjuk az y_j neuron általt visszaadott kimeneti értéket. Az aktivációs függvény lehet pl. küszöb függvény (negatív értékekre 0-t, pozitív értékekre 1-et ad), ReLU (*REctified Linear Unit*) aktivációs függvény (a negatív értékeket lenullázza), de gyakran valamilyen szigmoid függvényt választanak erre a célra (példa lehet erre a tangens hiperbolikus függvény: $\varphi(s) = \tanh(s)$) [cite Sharkawy].



1. ábra. A mesterséges neuron sematikus felépítése. Az ábra Sharkawy (2020) [6] cikkéből származik (CC BY-NC 4.0).

A neurális hálózatok neuronrétegekből állnak. Egyrétegű neurális hálózat esetén a bemenet és kimenet közt egyszeres összeköttetés van, azonban a gyakorlatban általában több neuronrétegből alkotják meg a neurális hálózatot. A több réteg (melyeket rejtett rétegeknek nevezünk – *hidden layers*) a bemeneti és kimeneti adatok közt több kapcsolatot jelent, és képes komplexebb összefüggések megtanulására is. A neuronok közti adattovábbítás iránya szerint megkülönböztetünk előrecsatolt neurális

hálózatokat (*Feedforward Neural Network, FNN*), illetve rekurrens neurális hálózatokat (*Recurrent Neural Network, RNN*). Az FNN-ekben nincsenek visszacsatolt kapcsolatok (*feedback-ek*), amelyekben a modellkimenetek önmagába visszakapcsolódnának. Ha a rejtett rétegek közt rekurrens kapcsolatokat is megengedünk, RNN-ről beszélünk. A rekurrens kapcsolatok egyfajta memóriát adnak a neurális hálózatnak, ezzel pedig lehetővé teszik pl. kontextus értelmezését [?].

1.3. Gépi tanulás alapú időjárás-előrejelző modellek

Az időjárás-előrejelzés területén a gépi tanulást már több, mint 25 éve használják (ld. pl. Hung et al., 2009, akik ANN-t használtak az eső előrejelzésére Bangkokban [*cite Hung et al.*]), azonban csak az utóbbi években ért el a technológia olyan fejlettséget, hogy operatív, több időjárási változóra is kiterjedő előrejelzést lehessen készíteni segítségével. Az MLWP-modellek több évtizednyi időjárási adat feldolgozása során fedezik fel a kapcsolatokat a légköri változók között, a kapcsolat ismeretében pedig már képesek előrejelzést is készíteni. A kapcsolat azonban nincs szabályozva a fizikai törvények által, ami az MLWP-modellek „fekete doboz” jellegét okozza. Ha viszont nem csak az ismert fizikai törvények érvényesülnek az előrejelzés készítése során, a hibás előrejelzések okának feltárása és a javítás rendkívül nehézé válik [4].

A következőkben néhány MLWP-modell működésén keresztül szeretném felvázolni, hogy miképpen lehet alkalmazni a gépi tanulós architektúrákat az időjárás előrejelzésére.

A 2023-ban nyilvánosságra hozott NVIDIA FourCastNet (*FOURier ForeCASTing Neural Network*) modell Fourier neurális hálózat alapú. Ez a fajta neurális hálózat Fourier Neural Operator-ok (*FNO*) és Vision Transformer-ek (*ViT*) együttes használatával létrejött Adaptive Fourier Neural Operator-ok (*AFNO*) segítségével épül fel.

1.4. Káoszelméleti bevezetés

A légkör egy kaotikus fizikai rendszer, ami azt jelenti, hogy a kis kezdeti hiba idővel exponenciálisan növekszik, azaz a kezdőfeltételekre rendkívül érzékeny. A kezdeti állapotot azonban nem ismerjük egészen pontosan, mivel nem léteznek tökéletes mérések.

A káosz kizárólag időben rendezetlen viselkedést jelent [7].

Hivatkozások

- [1] Jafar Alzubi, Anand Nayyar, and Akshi Kumar. Machine Learning from Theory to Algorithms: An Overview. *Journal of Physics: Conference Series*, 1142(1):012012, November 2018.
- [2] Massimo Bonavita. On Some Limitations of Current Machine Learning Weather Prediction Models. *Geophysical Research Letters*, 51(12):e2023GL107377, 2024. _eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2023GL107377>.
- [3] Rene Y. Choi, Aaron S. Coyner, Jayashree Kalpathy-Cramer, Michael F. Chiang, and J. Peter Campbell. Introduction to Machine Learning, Neural Networks, and Deep Learning. *Translational Vision Science & Technology*, 9(2):14, February 2020.
- [4] Catherine O. de Burgh-Day and Tennessee Leeuwenburg. Machine learning for numerical weather and climate modelling: a review. *Geoscientific Model Development*, 16(22):6433–6477, November 2023.
- [5] Aaron Lee, Paul Taylor, Jayashree Kalpathy-Cramer, and Adnan Tufail. Machine Learning Has Arrived! *Ophthalmology*, 124(12):1726–1728, December 2017.

- [6] Abdel-Nasser Sharkawy. Principle of Neural Network and Its Main Types: Review. *Journal of Advances in Applied & Computational Mathematics*, 7:8–19, August 2020.
- [7] Tamás Tél. TURBULENCIA VAGY KÁOSZ? ÚJ EREDMÉNYEK A CSŐBELI TURBULENCIA MEGÉRTÉSÉBEN.